山东大学本科毕业论文（设计）

面向 AI 生成内容的安全性研究与工具开发

姓名：麦世徐

学号：202200460157

专业：网络空间安全

指导教师：郭山清

2026 年 4 月 27 日

摘　要

随着生成式人工智能技术的快速发展，AI 生成内容在图像生成、视频生成、数字人驱动与智能创作等领域得到广泛应用，但同时也带来了虚假合成内容传播、不安全内容扩散、身份伪造和平台审核压力增加等问题。围绕 AIGC 内容在真实应用场景中的安全风险，本文以图像与视频两类典型媒体为研究对象，研究虚假内容检测与不安全内容识别方法，并在此基础上设计实现一个多模态内容安全检测与分析平台。

本文首先梳理 AIGC 生成技术、深度伪造技术以及安全检测领域的发展现状，分析现有方法在检测对象、泛化能力、部署成本和工程适配性等方面的特点。随后，围绕图像与视频安全分析任务，构建由前端展示层、后端代理层和模型推理层组成的系统架构，整合本地部署检测模型与外部多模态审核接口，形成统一的内容输入、检测分析、风险分级与结果可视化流程。系统支持图像与视频文件上传、URL 输入、虚假内容鉴别、不安全内容审核、检测结果展示与内容管理等功能，可为实验评估、样本构建和应用验证提供平台支撑。

在实验与分析部分，本文结合当前系统实现情况，对图像虚假检测、视频内容分析、不安全内容审核和平台可用性进行验证。结果表明，本地图像检测模块能够在 ProGAN mini 子集上完成稳定的基线验证，后端代理层能够将本地模型与外部多模态接口统一封装为可展示结果，平台已形成从内容生成、内容检测到风险展示的基本闭环。本文工作兼顾工程实现与应用价值，可为 AIGC 内容安全治理、网络平台审核以及多模态安全研究提供参考。

关键词：AIGC 安全；多模态检测；虚假内容检测；不安全内容识别；内容安全平台

ABSTRACT

With the rapid development of generative artificial intelligence, AI-generated content has been widely used in image synthesis, video generation, digital human animation, and intelligent media creation. Its increasing realism and accessibility also bring security risks such as forged content dissemination, unsafe media generation, identity misuse, and moderation pressure. Focusing on practical AIGC security scenarios, this thesis studies fake content detection and unsafe content recognition for images and videos, and designs a multimodal content security detection and analysis platform.

This thesis reviews AIGC generation technologies, deepfake manipulation methods, and mainstream detection approaches, comparing their detection targets, generalization ability, deployment cost, and engineering adaptability. Based on this analysis, a three-layer architecture is proposed, including the front-end presentation layer, back-end proxy layer, and model inference layer. By combining locally deployed detectors with external multimodal review APIs, the platform builds a unified workflow for content input, security analysis, risk grading, and result visualization. It supports image and video upload, URL-based input, fake content identification, unsafe content review, and output management.

In the experimental analysis, image fake detection, video content analysis, unsafe content review, and platform usability are verified according to the current implementation. The local image detector is evaluated on a ProGAN mini subset as a reproducible baseline, and the back-end proxy converts local model outputs and external API responses into structured results for front-end visualization. The results show that the platform has formed a basic closed loop from content generation and detection to risk presentation, providing a practical reference for deployable AIGC content governance tools.

Key words: AIGC security, fake content detection, multimodal review, content security platform

目录

第一章 绪论 **1**

1.1 研究背景与意义 1

1.2 国内外研究现状 1

1.2.1 AIGC 生成技术研究现状 1

1.2.2 AI 生成内容检测研究现状 1

1.2.3 不安全内容审核研究现状 2

1.2.4 现有研究的不足与问题分析 2

1.3 研究内容与技术路线 2

1.3.1 主要研究内容 2

1.3.2 技术路线 3

1.4 论文特色与创新点 3

1.5 论文结构安排 3

第二章 相关技术与理论基础 **4**

2.1 AIGC 图像与视频生成技术基础 4

2.1.1 图像生成技术演进 4

2.1.2 视频生成技术路线 4

2.1.3 AIGC 生成内容的安全相关特征 5

2.2 Deepfake 与多模态内容伪造技术 5

2.2.1 面向人脸的深度伪造技术 5

2.2.2 面向通用场景的多模态伪造与编辑技术 6

2.3 虚假内容检测方法 6

2.3.1 基于低层统计与频域特征的检测方法 6

2.3.2 基于监督分类的检测方法 6

2.3.3 基于通用视觉表征与重建对比学习的检测方法 6

2.3.4 面向视频的时序检测方法 7

2.3.5 不同检测方法的比较与适用场景 7

2.4 不安全内容检测与安全审查方法 7

2.4.1 内容安全审查的任务目标 7

2.4.2 基于视觉分类的内容审核方法 8

2.4.3 基于多模态大模型的安全审查方法 8
2.4.4 生成安全评测与防护研究的启示 8
2.5 系统开发关键技术 9
2.5.1 前端交互与可视化技术 9
2.5.2 后端代理与服务编排技术 9
2.5.3 模型服务化部署技术 9
2.6 本章小结 9

第三章 系统需求分析与总体设计 10
3.1 系统建设目标 10
3.2 功能需求分析 11
3.2.1 图像与视频输入 11
3.2.2 虚假内容检测 12
3.2.3 不安全内容审核 12
3.2.4 内容生成、展示与管理 13
3.3 非功能需求分析 13
3.3.1 可扩展性需求 13
3.3.2 可维护性需求 14
3.3.3 响应性能需求 14
3.3.4 安全性与可部署性 14
3.4 系统总体架构设计 15
3.4.1 总体架构设计思路 15
3.4.2 前端展示层设计 15
3.4.3 后端代理层设计 16
3.4.4 模型推理与外部能力层设计 16
3.5 系统核心业务流程设计 16
3.5.1 内容检测流程设计 16
3.5.2 生成与闭环验证流程设计 17
3.5.3 结果管理与追踪流程设计 17
3.6 模块划分与接口关系设计 18
3.6.1 功能模块划分 18
3.6.2 统一输入输出设计 18
3.6.3 模块间协同关系 19
3.7 本章小结 19

第四章 关键模块与平台实现 20
4.1 多源检测框架实现 20
4.1.1 统一能力组织思路 20
4.1.2 输入参数与结果结构标准化 21

4.2 图像虚假内容检测模块实现 21
4.2.1 本地检测模型接入实现 21
4.2.2 外部图像 AI 鉴别接口接入实现 22
4.3 视频虚假内容检测模块实现 23
4.3.1 视频理解接口接入实现 23
4.3.2 视频检测结果结构化实现 23
4.4 不安全内容检测模块实现 24
4.4.1 图像安全审核模块实现 24
4.4.2 视频安全审核模块实现 24
4.5 样本生成与内容管理模块实现 25
4.5.1 生成模块实现 25
4.5.2 数据管理模块现状与实现方式 25
4.6 风险分级与可视化展示实现 25
4.7 前后端平台开发与部署实现 26
4.7.1 前端页面与交互实现 26
4.7.2 后端代理与任务调度实现 27
4.7.3 模型服务部署实现 28
4.8 本章小结 28

第五章 实验设计与结果分析 29
5.1 实验目标与取舍原则 29
5.2 实验环境与评价指标 29
5.2.1 实验环境 29
5.2.2 评价指标 29
5.3 数据集与测试样本构建 30
5.3.1 图像真假检测样本 30
5.3.2 视频与安全审核样本 30
5.3.3 实验样本组织策略 31
5.4 图像虚假内容检测实验与分析 31
5.4.1 实验目的与方案 31
5.4.2 阶段性结果分析 31
5.5 视频检测与安全审核验证 31
5.5.1 视频真假检测验证 31
5.5.2 不安全内容审核验证 32
5.5.3 功能验证结果讨论 32
5.6 系统性能与可用性分析 32
5.6.1 响应特征分析 32
5.6.2 平台可用性分析 33

5.7 实验结果综合分析 33
5.8 本章小结 34

第六章 总结与展望 **35**
6.1 全文工作总结 35
6.2 存在的不足 35
6.3 后续研究展望 36

参考文献 **37**

致谢 **40**

附录 **41**
附录 A 补充代码与接口说明 41
附录 B 运行与复现实验说明 41

第一章　绪论

1.1　研究背景与意义

近年来，生成式人工智能在图像生成、视频生成、数字人驱动和智能创作等任务中快速发展，生成对抗网络、扩散模型和多模态大模型显著降低了数字内容生产门槛 [1, 4, 6]。与此同时，AI 生成内容与真实内容之间的边界逐渐模糊，虚假信息传播、不安全内容生成和平台治理压力也随之增加。

在图像与视频场景中，AIGC 安全风险主要体现在三方面：一是虚假内容风险，攻击者可利用文生图、图生视频、换脸和属性编辑生成高逼真伪造内容；二是不安全内容风险，生成模型可能输出暴力、色情、仇恨等违规信息；三是治理效率风险，人工审核难以长期应对海量多模态内容。构建自动化、可扩展的安全分析工具，既有助于完善多模态内容安全研究，也能为内容审核、新闻核验和网络治理提供工程支撑。

1.2　国内外研究现状

1.2.1　AIGC 生成技术研究现状

图像生成技术经历了从生成对抗网络到扩散模型的转变。GAN 类方法通过生成器与判别器的对抗训练建模图像分布，在人脸生成、图像翻译和风格迁移中较早取得突破 [1, 2, 3]。扩散模型则通过逐步加噪与逆向去噪生成图像，训练稳定性和生成质量更高，以 Stable Diffusion 为代表的模型推动了文生图、图像编辑和多条件控制等应用发展 [4, 5, 6, 7, 19]。模型能力提升和工具链开源使伪造内容构造门槛进一步降低。

视频生成技术在时序建模、多帧一致性和跨模态对齐方面持续演进，文本到视频、图像到视频和数字人驱动等路线已能生成具备动作和场景变化的短视频。Deepfake、人脸替换、人脸动画和属性编辑技术也在视觉真实感与动作自然度上不断提升，使虚假视频更具欺骗性，并使多模态内容安全问题更加复杂。

1.2.2　AI 生成内容检测研究现状

AI 生成内容检测已形成多条路线。早期方法主要从纹理分布、频域伪影、颜色统计和成像噪声等低层特征出发，利用真实内容与生成内容之间的分布差异进行判

别 [9, 22]。这类方法解释性较强，但面对新型生成模型时容易泛化不足。

随着深度学习发展，基于卷积神经网络和 Transformer 的监督检测方法逐渐成为主流 [13, 14]。它们能从标注样本中学习复杂判别特征，但对训练数据分布依赖较强。为提升跨模型泛化能力，研究者开始利用大规模预训练视觉模型或视觉语言模型提取通用表征，并通过轻量分类头、近邻检索或重建对比机制完成检测 [8, 10, 12]。在视频方向，逐帧检测、时序建模、局部与全局联合分析以及训练自由检测方法均被用于捕捉帧间不连续、口型不一致和局部结构异常等特征。

1.2.3　不安全内容审核研究现状

不安全内容审核关注内容本身是否涉及暴力、色情、仇恨、敏感符号或其他违规风险。传统方法多基于图像分类、目标检测和多标签识别，在固定类别场景中具有较好效果；多模态大模型则能够结合视觉输入与自然语言规则，输出风险标签、建议处置和原因说明，适合复杂开放场景。

从部署角度看，单一方法难以同时满足识别范围、推理效率、成本和可维护性要求。本地模型具备自主可控优势，但部署和更新成本较高；外部接口接入便捷、覆盖面较广，却存在依赖和成本问题。因此，如何将本地模型、外部接口和多模态大模型统一组织为可用平台，是当前研究与工程实践中的重要问题。

1.2.4　现有研究的不足与问题分析

综合现有研究，AIGC 安全分析仍存在三点不足：图像检测、视频检测和内容审核常分散在不同任务框架中，缺少一体化平台；算法效果与工程可用性存在落差，本地模型、云端接口和多模态大模型缺少统一接入与比较机制；检测结果的解释、风险分级和记录管理仍不完善，难以直接服务教学、科研和平台治理。本文因此从系统集成与工程实现出发，构建面向 AIGC 安全的多模态内容检测与分析平台。

1.3　研究内容与技术路线

1.3.1　主要研究内容

围绕 AIGC 图像与视频内容的真实性风险和安全性风险，本文主要开展四方面工作。

第一，构建面向平台实现的 AIGC 内容安全问题框架，将风险划分为虚假内容风险、不安全内容风险和平台治理风险，并区分图像、视频两类输入媒介的检测需求。

第二，研究多源检测能力的组织方式。图像虚假检测接入本地 UniversalFakeDetect 模型作为可复验基线，开放场景图像/视频检测和安全审核接入多模态接口，并通过统一输入参数、结果字段和风险等级消解不同能力之间的协议差异。

第三，设计并实现多模态内容检测与分析平台。平台采用前端展示层、后端代理层、模型推理与外部能力层分离的结构，实现内容上传、URL 输入、图像/视频虚假检测、图像/视频安全审核、内容生成、结果可视化和检测记录组织等功能。

第四，围绕平台可用性与检测链路有效性开展验证。实验结合 ProGAN 测试样本、平台生成样本和典型图像/视频素材，重点说明当前平台中可稳定运行的能力、适合作为研究基线的能力，以及仍需后续补强的外部依赖能力。

1.3.2　技术路线

本文遵循“问题分析、方法整合、平台实现、实验验证”的技术路线。首先调研 AIGC 生成与检测方法，明确虚假内容检测和不安全内容识别两类任务；其次结合开源模型与外部审核接口，构建统一检测能力接入框架；再次通过后端代理实现鉴权封装、接口转发、异步轮询和结果标准化处理，并在前端完成上传、检测、展示和管理等交互；最后围绕检测效果、响应特征和平台可用性开展实验分析。

1.4　论文特色与创新点

本文的特色主要体现在三方面。第一，面向图像与视频场景，将“是否为 AI 生成”和“内容是否存在违规风险”拆分为相互独立但可联合展示的两类判断，形成更完整的内容安全工作流。第二，提出并实现本地模型与外部接口结合的混合检测架构，用 UniversalFakeDetect 形成可复验图像检测基线，用多模态接口补充视频理解、开放场景鉴别和安全审核能力。第三，将风险分级、结果可视化和平台交互纳入整体研究范围，使平台不只返回模型原始响应，而是输出可理解、可展示、可追踪的安全分析结果。

需要说明的是，本文创新重点不在于提出全新的底层检测算法，而在于将已有模型、生成能力和审核能力组织为一个可运行、可验证、可扩展的安全分析平台，这与系统设计与实现型毕业论文主题一致。

1.5　论文结构安排

本文共六章。第一章介绍研究背景、现状、研究内容、技术路线和创新点；第二章梳理 AIGC 生成、深度伪造、虚假检测、不安全内容审核和系统开发技术；第三章重点分析系统目标、需求、总体架构、业务流程和接口设计；第四章说明多源检测、图像/视频检测、安全审核、生成管理和部署实现；第五章给出实验设计、样本构成、检测验证和可用性分析；第六章总结全文，分析不足并提出后续方向。

第二章　相关技术与理论基础

AIGC 安全分析涉及生成模型、伪造检测、内容审核和平台工程实现。本章围绕图像与视频生成、虚假内容检测、不安全内容审核，以及前后端分离、代理调度和模型服务化等工程基础展开，为后续系统设计提供依据。

2.1　AIGC 图像与视频生成技术基础

2.1.1　图像生成技术演进

图像生成技术主要经历了从生成对抗网络到扩散模型的演进。GAN 通过生成器与判别器之间的对抗训练学习数据分布，在人脸生成、图像翻译、风格迁移和属性编辑等任务中较早取得突破 [1, 2, 3]。其生成速度较快，但训练稳定性不足，复杂场景和高分辨率细节表达存在局限。

扩散模型通过正向加噪和逆向去噪完成生成建模，在训练稳定性和图像质量上更具优势 [4, 5]。以 Latent Diffusion Model 和 Stable Diffusion 为代表的模型在潜空间中扩散和去噪，降低了计算成本，并提升了文本对齐、高分辨率表达和可控生成能力 [6, 7, 19]。从安全视角看，生成质量提升使早期依赖 GAN 指纹、频域伪影和颜色异常的检测方法不再稳定，检测器需要更强的跨模型泛化能力。

扩散模型的工程化应用通常由文本编码器、去噪网络、采样调度器和图像解码器共同完成。采样步数、提示词权重、随机种子和后处理策略都会影响图像质量，也会改变纹理、边缘和噪声表现。因此，AIGC 检测不能只依赖某一种固定伪影，而需要同时考虑模型来源、生成参数和后处理链路对检测特征的影响。

2.1.2　视频生成技术路线

视频生成不仅要求单帧视觉质量，还要保持时间维度上的运动连续性和语义一致性。常见路线包括文本到视频、图像到视频和人物驱动动画。文本到视频模型根据文本条件生成连续画面；图像到视频模型以首帧或参考图为基础生成动态片段；人脸或人体驱动模型则利用关键点、运动场或驱动视频迁移表情、口型和姿态。

以本文原型系统接入的 ModelScope Text-to-Video 类模型为例，其通常采用扩散机制和时空建模结构生成短视频 [20]。这类模型能够生成较自然的片段，但在复杂动

作、长时一致性、文字渲染和物理规律表达上仍可能出现局部闪烁、结构漂移和运动不连续等问题，这些现象也为视频检测提供了线索。

与图像生成相比，视频生成的安全分析需要额外关注时间维度。单帧画面可能具备较高真实感，但相邻帧之间仍可能出现身份漂移、边界跳变、纹理闪烁和运动方向不一致等问题。对于人脸或数字人视频，还需要关注口型、眼部动作、头部姿态和语音语义是否协调。因此，视频检测不仅需要视觉分类，还需要对整段内容的动态语义进行综合判断。

2.1.3　AIGC 生成内容的安全相关特征

生成内容通常在低层统计、局部语义、时序动态和安全对齐方面留下可分析特征。低层统计特征包括噪声分布、纹理连续性、频谱结构和压缩残留差异；局部语义特征包括边缘不稳定、细粒度结构错误和区域不连贯；视频时序特征包括运动轨迹异常、帧间差异不自然和长时结构漂移；安全对齐问题则表现为模型在诱导性提示下可能输出违规内容。

这些特征并不总是稳定出现。高质量生成模型会削弱明显伪影，社交平台压缩、裁剪和滤镜也可能掩盖原始痕迹；真实图像在低光照、强压缩或快速运动下也可能产生类似异常。因此，平台不能把单一线索等同于最终结论，而应通过置信度、风险标签和原因说明表达不确定性。

因此，本文同时关注两类任务：一类识别内容是否由 AI 生成或被深度伪造，另一类识别内容是否具有不安全属性。前者强调真实性和来源分析，后者强调风险等级和治理要求，二者在平台中分别建模、统一展示。

2.2　Deepfake 与多模态内容伪造技术

2.2.1　面向人脸的深度伪造技术

Deepfake 是 AIGC 安全研究中的典型风险场景，广义上指利用深度学习模型对人脸身份、表情、口型、语音或姿态进行替换、重建和驱动的技术集合 [13, 14, 21, 22]。身份替换关注将源身份迁移到目标场景；表情迁移和口型同步关注动作与语音的一致性；属性编辑则通过文本或标签修改年龄、发型、妆容和背景等特征。

人脸伪造的风险后果更直接，容易触发身份冒用、名誉损害、舆论误导和诈骗等问题。因此，人物图像和人物视频既是虚假检测的重要对象，也是系统设计中必须覆盖的典型输入类型。

从检测角度看，人脸伪造既有局部线索，也有跨帧线索。局部线索包括面部边缘融合不自然、肤色与光照不一致、眼镜和头发等细节区域变形；跨帧线索则包括眨眼频率异常、口型与语音不匹配、面部身份在运动中轻微漂移等。由于这些线索会随生成算法和后处理方式变化，本文平台没有将 Deepfake 检测限定为单一人脸算法，而

是把它纳入更一般的图像与视频虚假内容检测流程。

2.2.2　面向通用场景的多模态伪造与编辑技术

AIGC 伪造风险已从人脸换脸扩展到通用场景构造。文生图模型能够快速生成新闻场景、灾害画面和拟真肖像，文本到视频和图像到视频模型还能生成带有动作和镜头变化的动态内容。与人脸伪造相比，通用场景伪造更难依赖固定局部区域检测，往往涉及物理规律错误、对象关系异常、时序动作不自然和语义逻辑不一致等问题。因此，检测方法需要更强的开放域泛化能力。

2.3　虚假内容检测方法

2.3.1　基于低层统计与频域特征的检测方法

较早的伪造检测方法依赖图像处理和媒体取证思想，通过颜色分布、噪声模式、压缩残留、插值痕迹和频域特征识别异常 [9, 15, 22]。这类方法可解释性较强，适合辅助定位异常区域，但对后处理、压缩、裁剪和分辨率变化较敏感。随着扩散模型生成质量提高，早期明显伪影被削弱，因此低层统计方法更适合作为辅助分析，而难以单独支撑开放场景检测。

2.3.2　基于监督分类的检测方法

监督分类方法将伪造检测建模为二分类或多分类任务，利用卷积神经网络、Transformer 等视觉编码器从真实与伪造样本中学习判别边界 [9, 11]。在人脸伪造场景中，FaceForensics++ 等数据集推动了面部裁剪、局部注意力、压缩鲁棒性和多任务学习等研究 [13]。这类方法在训练集和测试集分布相近时效果较好，但面对未见过的新模型、压缩链路或跨模态场景时容易退化。

监督分类方法的工程优势在于推理流程明确，模型输出通常可以直接转换为概率、标签和阈值判定，便于服务化部署和批量评测。但其效果高度依赖训练样本的覆盖范围。如果训练集中主要包含某一类 GAN 图像，模型可能学习到该生成器特有的纹理痕迹，而不是更通用的“AI 生成”特征。因此，在本文平台中，本地模型更适合作为可复验基线和实验入口，而不应被理解为覆盖所有开放场景的唯一判断来源。

2.3.3　基于通用视觉表征与重建对比学习的检测方法

为缓解跨模型泛化不足，研究者开始利用大规模预训练视觉模型或视觉语言模型提取通用特征，再通过近邻搜索、线性分类头或轻量探测器判断真实性 [8]。UniversalFakeDetect 就是该思路的代表，其借助预训练特征空间中的判别能力提高对未知生成模型的适应性 [10]。

重建与对比学习方法则通过构造高质量重建样本和困难伪造样本，引导检测器关注更稳定的生成痕迹。以 DRCT 为代表的研究表明，若模型能区分与真实图像高度相似的困难伪造样本，在未知扩散模型上也更可能保持性能 [12]。这类方法更符合生成模型快速迭代背景下的检测需求。

通用表征方法与本文系统设计关系较密切。一方面，它们不要求平台重新训练大型视觉主干，适合在毕业设计阶段形成可运行的本地检测服务；另一方面，预训练特征本身仍需要阈值选择、结果解释和异常处理。也就是说，算法模型只能给出判别分数，平台层还必须负责把分数转换为用户可理解的结论、置信度和说明文本。

2.3.4　面向视频的时序检测方法

视频检测比图像检测多出时间维度，因此更关注帧间一致性、动作规律和动态差分。传统方法可逐帧检测后再聚合，也可使用三维卷积、循环网络或时空 Transformer 建模短片段。近年来，训练自由或弱训练方法开始关注真实视频与 AI 生成视频在运动变化规律上的差异。以 D3 为代表的方法利用时间差分和二阶动态特征检测 AI 生成视频 [16]，说明单帧逼真并不代表整体时序自然。

2.3.5　不同检测方法的比较与适用场景

不同检测路线各有适用场景：低层统计方法解释性强但泛化不足；监督分类方法封闭集效果好但依赖训练分布；通用视觉表征方法更适合开放图像检测；视频时序方法能利用动态异常但部署复杂；多模态大模型接入灵活、解释能力较强，但成本、稳定性和依据透明度仍需约束。本文将主要路线归纳如表 2.1 所示。

对于本文平台，单一方法难以同时覆盖图像、视频、真实性和安全性任务。因此，本文采用“本地图像检测模型 + 外部多模态理解能力”的混合方案：本地模型提供可控、可复验的研究基线，外部接口补充视频理解、开放场景判别和安全审核能力。

2.4　不安全内容检测与安全审查方法

2.4.1　内容安全审查的任务目标

内容安全审查关注内容是否违反平台规则、法律规范或伦理要求，而不是判断其是否由 AI 生成。在 AIGC 场景下，生成模型可能输出暴力、色情、仇恨、毒品、赌博或其他违规内容，也可能产生边界模糊的擦边、暗示和符号化风险。因此，审核结果需要包含风险类别、建议处置方式、风险等级和原因说明，而不应只有简单二分类标签。

在实际业务中，内容审核往往不是一次模型判断即可结束，而是一个分层处置过程。低风险内容可直接通过，中风险内容进入人工复审，高风险内容应阻断或重点核

表 2.1: 虚假内容检测方法比较

方法类别	主要依据	优势	局限与适用场景
低层统计与频域方法	噪声、纹理、频谱、压缩痕迹	可解释性较强，适合媒体取证辅助分析	对后处理敏感，面对高质量扩散模型时泛化不足
监督分类方法	标注数据中学习到的判别边界	封闭数据集内精度较高，部署链路成熟	依赖训练分布，跨生成模型和跨压缩链路容易退化
通用视觉表征方法	大规模预训练模型特征空间	泛化能力较好，适合作为开放域图像检测基线	对预训练特征质量敏感，通常仍需阈值或轻量分类头
视频时序检测方法	帧间一致性、运动规律、动态差分	能利用单帧图像中不明显的时序异常	计算和数据处理成本较高，本地部署复杂度更大
多模态大模型判别	视觉输入与自然语言提示联合推理	接入灵活，适合开放场景解释与快速原型	成本、稳定性和可解释依据仍需平台层面约束

查。本文平台采用低、中、高三档风险表达，将不同审核接口的原始输出转化为统一治理语义，使安全审核结果能与虚假检测结果并列展示。

2.4.2　基于视觉分类的内容审核方法

传统审核方法多基于图像分类、目标检测和多标签识别模型，适合暴力、色情、血腥、武器等类别明确的业务场景。其优点是任务定义清晰、推理速度快、部署成熟；局限是对语境依赖、隐喻表达和复合风险处理不足。视频审核还需要理解动作过程和上下文语义，复杂度高于静态图像。

2.4.3　基于多模态大模型的安全审查方法

多模态大模型能够同时接收图像、视频和文本提示，并输出风险结论、标签和解释，在开放类别识别和复杂语义推理上具有优势。工程上可通过提示词将审核任务约束为结构化输出，例如要求围绕暴力、色情、仇恨、敏感符号和违法活动给出安全结论、标签集合和处置建议。该方法扩展性强，但也存在结果稳定性受提示词影响、成本较高和决策依据不透明等问题，因此更适合作为规则系统和传统分类器的补充。

2.4.4　生成安全评测与防护研究的启示

近年来，研究者还关注生成模型本身的安全评测和前置防护。例如，视频生成安全评测基准从多类风险维度评估文本到视频模型安全性，说明视频生成不仅要关注

画质和时序一致性，还要关注输出风险 [17]。相关有害性识别数据集也表明，生成安全正在从“输出检测”扩展到“全流程治理”[18]。本文平台主要聚焦生成后检测与分析，因此在设计上需要同时覆盖真假鉴别、内容合规和风险处置表达。

2.5　系统开发关键技术

2.5.1　前端交互与可视化技术

面向 AIGC 安全分析的平台不仅要完成模型调用，还要提供清晰稳定的交互界面。React 与 TypeScript 适合构建模块化前端，Vite 提供轻量开发和构建能力，Ant Design 提供表单、上传、标签、进度和反馈等常用组件。前端展示层的核心职责是将复杂模型调用转化为统一操作流程，包括文件上传、链接输入、任务选择、进度反馈、结果可视化和历史记录查看。

2.5.2　后端代理与服务编排技术

本文涉及本地模型、外部审核接口和多种输入输出协议，后端需要承担统一代理和服务编排功能。Node.js 与 Express 具有实现成本低、异步处理方便和前端生态衔接自然等特点。后端代理层负责鉴权封装、参数校验、格式转换、任务路由、异步轮询、错误处理和结果标准化，是实现多源能力统一组织的关键。

2.5.3　模型服务化部署技术

本地检测和生成功能需要以服务化方式接入平台。FastAPI 等 Python Web 框架便于将 PyTorch 模型封装为 HTTP 接口，完成模型加载、输入预处理、推理、后处理和状态监测。模型服务化能够将算法脚本转化为可复用组件，使前端、后端和模型之间形成清晰边界，也为模型替换、远程部署和多模型扩展提供基础。

对本文系统而言，服务化部署使本地模型、外部接口和前端页面以统一协议协同工作。模型侧关注预处理和推理结果，后端侧负责鉴权、路由、容错和字段映射，前端侧处理交互和可视化展示。这种分层方式降低单个模块变化对整体系统的影响，也为后续接入更多检测模型和审核接口提供工程基础。

2.6　本章小结

本章梳理了 AIGC 图像与视频生成、Deepfake 与通用场景伪造、虚假内容检测、不安全内容审核以及平台实现相关工程技术。综合来看，生成模型演进使伪造内容来源更复杂、逼真程度更高，而检测与审核方法各有优势和局限。面向真实应用场景的 AIGC 安全平台需要采用多源能力协同、统一结果结构和模块化部署相结合的设计思路。

第三章　系统需求分析与总体设计

多模态 AIGC 安全分析平台需要将图像、视频、生成模型、检测模型和外部审核接口组织为统一系统。仅有单个模型或单个页面并不能支撑完整的安全分析任务，平台还需要明确输入形式、任务边界、结果结构、模块职责和部署约束。本章围绕系统建设目标、功能需求、非功能需求、总体架构和业务流程展开分析，将课题目标转化为可实现的系统设计方案。

3.1　系统建设目标

本文所研究的系统并不是一个单纯的模型演示页面，而是一个围绕 AIGC 安全分析任务构建的多模态内容检测与分析平台。该平台的建设目标可以概括为“面向图像与视频内容，形成可接入、可分析、可展示、可扩展的 AIGC 安全研究原型”。围绕这一目标，系统设计需要同时满足研究验证、工程演示和后续扩展三个层面的要求。

从研究验证角度看，平台应能够承载虚假内容检测与不安全内容审核两类核心任务，并支持本地模型与外部接口的统一接入。这样做的原因在于，本文的目标并非局限于调用某一个现成接口，而是希望在统一平台中比较不同检测能力的适用场景、组织方式和可扩展性。因此，系统必须具备多源模型管理与统一结果表示能力。

从工程演示角度看，平台需要具备完整的交互闭环，包括内容输入、任务触发、结果返回、风险展示和历史追踪等环节。只有在业务链路上形成闭环，系统才能既服务于实验验证，又能够支撑功能展示和持续扩展。换言之，平台不仅要“能跑通模型”，还要“能被用户使用”，这也是本文区别于纯算法复现工作的一个重要特征。

从持续扩展角度看，系统应具备灵活的模块替换能力。AIGC 安全研究处于快速发展阶段，无论是生成模型还是检测方法都在持续迭代。如果平台在设计之初就将不同模型、不同输入模态和不同结果结构紧密耦合，模型替换和能力扩展成本会非常高。因此，系统需要在架构层面保持较强的松耦合特征，使前端界面、后端代理、模型服务和外部接口之间能够通过统一协议协同工作。

基于上述分析，本文将系统设计目标进一步细化为以下几点：第一，支持图像与视频两类输入媒介，并兼容文件上传和链接输入两种常见方式；第二，支持虚假内容检测和不安全内容审核两类安全任务；第三，支持本地模型与外部接口协同工作，形成多源能力统一接入框架；第四，支持检测结果可视化、风险分级和历史管理；第五，支持内容生成与检测联动，为样本构建与实验验证提供平台基础。围绕这些目标展开

的需求分析，将直接决定系统总体架构与模块划分方式。

图 3.1: 平台首页与整体功能模块

3.2　功能需求分析

3.2.1　图像与视频输入

作为面向多模态内容的安全分析平台，系统首先需要解决输入层面的统一性问题。本文关注的对象包括静态图像和短视频两类内容，它们在文件格式、体积大小、预处理流程和展示方式上存在明显差异。因此，系统必须在输入环节兼顾统一性与差异性：统一性体现在用户操作方式和业务入口要尽量一致；差异性体现在图像与视频需要采用不同的预处理与展示逻辑。

具体而言，系统应至少支持本地文件上传与 URL 输入两种方式。本地上传适用于实验样本、个人素材和平台生成结果的直接检测，能够保证研究过程中样本来源可控；URL 输入则更贴近实际应用场景，能够用于快速分析网络内容或远程素材。由于图像与视频的体积差异较大，系统在接收本地文件时还需要考虑大小限制、预览生成和编码转换问题。对于图像，可以较方便地进行 Base64 编码和前端预览；而对于视频，则需要在文件大小、上传方式和播放预览之间做权衡，以防止系统在前端或后端阶段出现性能瓶颈。

此外，输入需求不仅包括“能上传内容”，还包括“能识别内容类型并进入正确流程”。平台应能够区分图像检测、视频检测、图像安全审核和视频安全审核等不同

业务分支，并在前端交互层面为用户提供明确的任务选择入口。否则，即使底层能力充足，也会因为用户操作路径混乱而降低平台可用性。

3.2.2　虚假内容检测

虚假内容检测是本文系统的核心能力之一，其目标是判断输入内容是否由 AI 生成、是否经过深度伪造或是否存在明显合成痕迹。结合第一章和第二章的分析，可以看出该任务既包括开放域图像检测，也包括视频真假判别，还涉及人脸换脸、图像编辑和文生视频等多类伪造来源。因此，系统在功能设计上必须兼顾任务的通用性与检测结果的可理解性。

首先，系统应支持图像虚假检测与视频虚假检测两类子任务，并允许不同检测后端并行存在。对于图像检测，平台既需要支持本地模型完成较可控的研究复现，也应支持调用外部多模态模型完成更开放场景下的真假判别。对于视频检测，由于本地视频检测模型复现成本较高、资源消耗较大，系统还需要允许外部接口作为现实可行的主方案。这样的设计使平台能够在“研究可控性”和“工程适用性”之间取得平衡。

其次，虚假内容检测需求并不止于输出一个真假标签。更有价值的是提供结构化结果，包括真假结论、置信度、模型来源、必要的原因说明以及可选的辅助判断信息。这样做有两方面意义：一方面，它能够提升结果可解释性，使用户能够理解模型判断依据；另一方面，它也为多模型比较、风险融合和实验统计提供统一数据基础。

再次，系统需要支持“生成—检测”联动。考虑到本文课题不仅研究检测，还涉及内容生成与样本构建，因此虚假检测模块应能够方便接收平台内部生成的图像与视频结果，并完成即时分析。换言之，检测系统既要能分析外部输入，也要能分析平台自身生成的输出，这一点对于实验样本构建和闭环验证至关重要。

3.2.3　不安全内容审核

与虚假内容检测相比，不安全内容审核更强调内容风险类型与处置建议的输出。系统需要识别的并不是“内容是真是假”，而是“内容是否涉及暴力、色情、仇恨、赌博、敏感符号或其他违规属性”。这意味着审核模块在设计上必须同时支持标签化分类、风险等级判断和说明性输出。

从任务形式上看，不安全内容审核同样需要同时支持图像和视频。对于图像审核，重点是识别静态场景中的违规内容类别；对于视频审核，除了识别单帧场景中的不安全元素，还需要考虑整段视频语义和时序动作过程所带来的风险。这种模态差异决定了系统不能简单地将图像审核逻辑直接复制到视频流程中，而是需要在交互入口、输入参数和结果呈现方式上做有针对性的区分。

在结果设计方面，审核模块应至少输出安全与否、风险标签、建议处置方式和原因说明。其中，建议处置方式可以设计为“通过”“复审”“阻断”等层次，用于体现平台对不同风险程度内容的区分能力。这样设计不仅更接近真实业务平台的审核逻辑，也便于在系统中实现统一的风险分级展示。

此外，不安全内容审核需求与虚假内容检测需求之间应保持相互独立但可联合展示的关系。某些内容可能是 AI 生成但不一定违规，某些内容可能真实拍摄却包含高风险信息。因此，系统设计不能将两类任务简单合并为一个判断器，而应允许它们分别输出各自结果，并在界面层面统一呈现。这种设计有助于形成清晰的风险分级与结果解释机制。

3.2.4　内容生成、展示与管理

虽然本文的重点是安全分析，但从整体研究路线看，内容生成模块同样具有重要作用。首先，它能够为虚假检测与审核实验提供可控样本来源，尤其是在公开数据集不完全覆盖目标场景时，平台内生成能力可以帮助快速构造研究样本。其次，生成模块可以与检测模块形成闭环验证流程，使系统同时具备“内容生成”“内容检测”“结果回流”的一体化演示能力。基于此，平台需要支持若干典型生成任务，如文生图、文生视频、图生视频以及与 Deepfake 相关的人脸替换、人脸动画和属性编辑等。

仅有生成与检测能力仍不足以支撑完整平台，因此系统还应具备结果展示与内容管理能力。对于检测结果，平台需要支持图像或视频预览、风险标签、置信度、建议说明等信息的统一展示；对于生成结果和检测记录，平台需要支持保存、查看和后续管理。内容管理模块的意义在于将离散的模型推理结果组织成可追踪、可对比的研究资料，这一点对实验分析和结果复核都十分重要。

综合来看，生成、检测、展示与管理需求共同构成了平台功能闭环。若缺少任何一个环节，系统都将更接近“单点能力演示”，而不是完整的研究平台。因此，功能需求分析必须从整体链路出发，而不能只围绕单个模型接口来展开。

3.3　非功能需求分析

3.3.1　可扩展性需求

本文课题处于 AIGC 安全研究快速演进的背景下，系统若仅能适配当前已接入的几个模型，其研究价值将受到较大限制。因此，可扩展性是平台设计中最重要的非功能需求之一。系统应允许后续继续接入新的图像检测模型、视频检测模型、安全审核接口和生成模型，并尽量减少对前端页面和已有模块的改动范围。

为满足这一需求，平台在设计上应采用模块化和接口化思路。前端尽可能围绕统一的数据结构渲染界面，后端则负责在不同能力之间做参数转换与结果标准化。这样，当未来引入新的检测方法时，只需在后端增加适配逻辑，而不必整体重构系统。对于毕业设计而言，这样的架构也更符合“可继续演进”的研究平台特征。

3.3.2　可维护性需求

系统涉及前端、后端、本地模型服务和外部接口多类组件，如果缺乏良好的可维护性设计，后续任何模块变动都可能影响整体稳定性。可维护性需求主要体现在三个方面。第一，职责清晰。前端负责交互与展示，后端负责调度与统一封装，模型服务负责推理逻辑，各层职责不应混淆。第二，数据结构统一。检测结果、生成结果和历史记录应使用相对稳定的数据模式，以减少页面层和业务层的耦合。第三，日志与错误处理可定位。系统在面对接口失败、模型超时、鉴权异常和输入不合法等情况时，应能够给出清晰提示，便于调试和排障。

如果一个平台只能在开发者本人熟悉的环境中偶然跑通，其工程价值是有限的。因此，系统需要通过清晰分层、统一接口和可定位错误处理保证基本可维护性，使平台能够在功能调整、模型替换和演示部署过程中保持稳定。

3.3.3　响应性能需求

内容安全分析平台虽然不是高并发商用系统，但仍需要满足基本的响应性能要求，否则将直接影响用户体验和实验效率。图像检测一般要求在较短时间内完成返回，以保证页面交互连贯；视频检测和视频生成则由于涉及更大数据量和异步任务，允许更长响应时间，但仍需要在平台层面对用户提供明确的进度反馈和状态说明。

因此，系统在设计时需要区分同步任务与异步任务。对于耗时较短的图像检测和图像审核，可采用同步请求直接返回结果；对于文生视频、图生视频及某些视频审核任务，则应通过后端代理层封装轮询逻辑，将复杂的异步流程转换为前端可接受的统一结果形式。提前区分两类任务能够避免前端页面直接承担复杂状态管理，也能降低长任务失败对用户体验的影响。

3.3.4　安全性与可部署性

作为 AIGC 安全分析平台，系统自身也需要满足基本安全性要求。首先，涉及外部接口调用时，密钥和鉴权信息不能暴露在前端。其次，本地模型服务和后端代理之间的调用关系应清晰可控，避免因接口配置混乱导致安全风险。再次，平台在处理用户上传内容时，应具备基本的输入检查与错误隔离能力，防止异常文件或不合规输入直接影响系统运行。

可部署性则强调平台不仅要能在本地开发环境中运行，还应能够迁移至实验室服务器或演示环境中进行展示。这要求系统在依赖管理、服务启动、端口规划和远程部署方式上具备一定规范性。结合本文当前原型进展，系统已采用前后端分离与模型服务独立运行的方式，因此可部署性也是总体设计中必须考虑的目标之一。

3.4　系统总体架构设计

3.4.1　总体架构设计思路

基于前述需求分析，本文将系统总体架构设计为前端展示层、后端代理层、模型推理与外部能力层三部分。之所以采用三层分离架构，而非将前端直接连接模型或将所有逻辑堆叠在单一服务中，主要基于以下考虑：其一，前端需要保持对多源能力的无感知，尽量以统一方式组织交互与结果展示；其二，后端需要集中处理鉴权封装、参数适配、结果标准化和异步调度；其三，本地模型与外部接口的接入方式差异明显，需要在系统边界上进行隔离。

这种三层结构本质上是一种面向研究原型的松耦合设计。它既能支持本地模型复现，又能保留调用外部能力的灵活性；既能满足实验中的方法对比需求，也能支撑功能扩展和部署演示。因而，该架构与本文“研究验证 + 工程实现”并重的课题定位是匹配的。

根据上述设计思路，本文平台总体架构如图 3.2 所示。该图并不强调某一个单独模型的内部结构，而是突出前端页面、后端代理、本地模型服务、外部能力接口与样本资源之间的协作关系。这样处理更符合本文系统设计型工作的重点，即说明多源能力如何被统一组织到同一安全分析平台中。

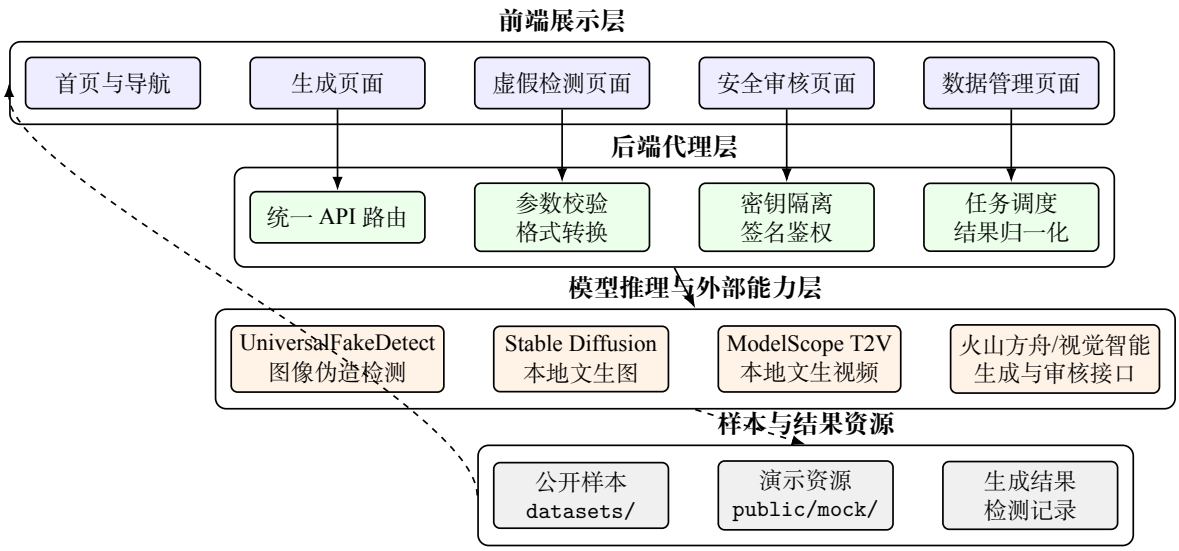

图 3.2: AIGC 安全分析平台总体架构

3.4.2　前端展示层设计

前端展示层是用户与平台交互的入口，主要承担内容上传、任务选择、检测触发、结果展示和历史查看等功能。从整体结构看，前端不负责算法推理与复杂业务编排，而是通过相对统一的组件结构组织不同页面。按照当前课题目标，前端可以划分为首

页、内容生成页、虚假检测页、不安全检测页和数据管理页等若干页面模块，各页面围绕具体业务场景提供相应操作入口。

为了提高系统一致性，前端展示层的设计原则是“统一入口、分任务展示、结果结构化”。即不同业务任务虽然在具体内容上存在差异，但用户都应遵循相近的操作流程：输入内容、选择任务、触发检测或生成、查看结果。这种统一交互模式能够降低系统复杂度，并增强平台的可演示性。

3.4.3　后端代理层设计

后端代理层是整个系统的核心枢纽。它位于前端与模型服务/外部接口之间，负责统一接收前端请求，并将其转发至正确的能力来源。更重要的是，该层承担了多源能力接入过程中的差异消解工作。例如，不同接口可能在鉴权方式、输入参数形式、异步处理机制和结果返回结构上存在明显不同，如果由前端直接处理这些差异，将导致页面逻辑复杂且难以维护。通过后端代理层统一封装后，前端只需面向统一业务接口即可。

在总体设计中，后端代理层需要支持三类核心任务：第一，统一请求入口，包括参数校验、内容格式转换和任务路由；第二，统一安全控制，包括密钥管理、签名计算和错误屏蔽；第三，统一结果结构，包括真假判断、风险标签、生成结果和历史记录的规范化表示。

3.4.4　模型推理与外部能力层设计

模型推理与外部能力层是系统真正执行检测与生成任务的能力来源，可进一步分为本地模型服务和外部接口服务两类。本地模型服务主要承担可控、可复现的研究任务，如本地图像虚假检测、本地文生图和本地文生视频等；外部接口服务则主要承担开放场景下的图像 AI 鉴别、视频 AI 鉴别以及图像/视频安全审核等任务。

这种“双来源能力层”设计与单一后端模型方案相比更符合本文课题实际。一方面，本地模型能够体现毕业设计在算法复现和自主部署方面的工作量；另一方面，外部接口能够弥补本地模型在多模态能力、视频审核能力和工程成熟度方面的不足。对平台而言，关键并不在于能力来源是否统一，而在于能否通过后端代理将这些异构能力组织为一个统一系统。

3.5　系统核心业务流程设计

3.5.1　内容检测流程设计

系统的基本检测流程可概括为“输入内容—任务选择—请求转发—结果解析—风险展示”。首先，用户在前端选择输入内容并指定任务类型，例如图像虚假检测、视频虚假检测、图像安全审核或视频安全审核。随后，前端将统一格式的请求发送给后

端代理层。后端根据任务类型和能力配置，将请求转发至对应的本地模型服务或外部接口，并在收到结果后完成字段标准化与状态归一化处理。最后，前端根据统一结果结构完成风险标签、置信度、原因说明和预览信息的展示。

为了使上述过程更加清晰，本文将内容检测流程抽象为图 3.3。该流程图体现了平台设计中的两个关键点：一是前端只面向统一任务入口，二是本地模型与外部接口均由后端代理层统一封装，最终以标准化结果返回前端展示。

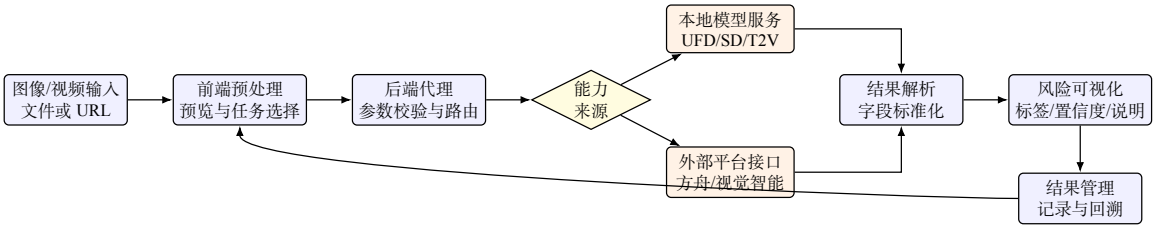

图 3.3: 内容安全检测业务流程

这一流程的关键在于“结果解析”环节。由于不同检测后端返回的数据结构差异较大，如果没有统一结果结构，前端就必须为每种能力编写单独渲染逻辑，系统复杂度会迅速增加。因此，在总体设计中，结果结构的统一性是业务流程顺畅运行的核心前提。

3.5.2　生成与闭环验证流程设计

除检测流程外，平台还需要支持“生成—检测—展示”的闭环验证流程。其基本逻辑是：用户先通过生成模块产生图像或视频内容，再将结果直接送入相应的检测模块，最后对生成样本的真假属性或安全属性进行分析。该流程在论文中的意义主要体现在两个方面。第一，它为实验样本构建提供平台内闭环来源，减少对外部数据的完全依赖。第二，它能够直观展示系统具备从生成到分析的完整链路，有利于体现平台整体性。

在总体设计层面，闭环验证流程并不要求所有生成结果都自动进入检测模块，而是要求平台在数据流上支持这种联动关系。也就是说，生成模块与检测模块之间应当能够共享输出数据或通过统一存储中转，从而避免重复上传和重复编码操作。

3.5.3　结果管理与追踪流程设计

为了支撑论文实验与系统演示，平台需要具备基本的结果管理与追踪流程。对于检测任务，应记录任务类型、输入来源、检测结论、风险标签、时间戳和必要的说明字段；对于生成任务，应记录生成类型、生成结果地址、生成时间和相关参数摘要。这样做的目的是将一次性的页面交互结果沉淀为可回溯的数据记录。

结果追踪流程的引入有助于解决两个问题：一是便于实验统计与人工核查，二是便于回看不同任务的示例结果。虽然当前平台尚不追求完整数据库化管理，但在总体设计中提前考虑结果管理机制，有利于模块扩展和功能完善。

3.6　模块划分与接口关系设计

3.6.1　功能模块划分

结合上述需求与业务流程，本文将平台划分为内容生成模块、虚假内容检测模块、不安全内容审核模块、数据管理模块和系统支撑模块五类。内容生成模块负责产出研究样本和演示素材；虚假内容检测模块负责判断内容真伪与 AI 生成属性；不安全内容审核模块负责识别内容风险类别与处置建议；数据管理模块负责结果查看、记录组织与后续分析支持；系统支撑模块则主要承担鉴权、代理、调度、日志和部署等功能。

这种模块划分方式的优点在于能够对应真实业务任务，便于用户理解系统结构，也便于在工程实现中分别维护生成、检测、审核和结果管理等功能。不同模块之间通过统一输入输出结构进行连接，既避免了功能耦合过重，也为后续接入新模型或扩展新任务保留了空间。

3.6.2　统一输入输出设计

在多源能力接入场景下，统一输入输出设计是降低系统复杂度的关键。对于输入层，平台应尽量将图像与视频内容统一抽象为“文件输入”与“链接输入”两种基本形式，再由后端根据任务需要完成 Base64 编码、URL 透传或其他格式转换。对于输出层，平台则应将不同后端返回的复杂结果归一化为若干核心字段，例如任务类型、判定结果、置信度、风险标签、说明文本、媒体预览地址等。

统一输入输出设计的重要价值在于，它使系统能够在不改变前端主流程的前提下替换底层能力。例如，当后续新增一个图像虚假检测模型时，只要该模型能够在后端层被适配为统一输出结构，前端页面就无需整体重写。这种设计思路也是平台可扩展性的直接体现。

根据当前平台的任务划分，本文将检测类结果抽象为表 3.1 所示的核心字段。该表并不对应某一个具体接口的原始返回，而是后端代理层归一化后的平台内部结果结构。通过这种方式，前端能够用相同的展示组件处理本地模型、多模态理解接口和内容审核接口返回的结果。

在风险等级映射上，本文采用相对克制的三档表达：低风险表示未发现明显问题或建议通过；中风险表示模型认为存在不确定因素，需要人工复审；高风险表示检测结果中存在较强伪造或违规信号，建议阻断或重点核查。这样设计的目的不是替代人工审核结论，而是把不同模型输出转换为一致的工程表达，使用户能够快速理解检测结果的严重程度。

表 3.1: 检测结果统一字段设计

字段类别	代表字段	设计说明
任务标识	taskType、mediaType	标记任务属于虚假检测或安全审核，以及输入媒介为图像或视频。
判定结论	isFake、safe、suggestion	虚假检测关注是否为 AI 生成或伪造；安全审核关注是否安全以及通过、复审、阻断等建议。
可信程度	confidence、riskScore	将模型分数或审核建议映射为 0 到 1 的置信度或 0 到 100 的风险分值，便于统一可视化。
风险解释	labels、reason、artifacts	保存风险标签、模型说明和可疑痕迹描述，提升检测结果的可解释性。
展示信息	previewUrl、model、details	记录预览资源、能力来源和任务细节，支持页面展示与实验回溯。

3.6.3 模块间协同关系

各功能模块并不是孤立运行的页面集合，而是围绕统一业务流程协同工作。内容生成模块负责产生图像或视频样本，虚假内容检测模块和不安全内容审核模块分别从真实性和安全性两个角度进行分析，数据管理模块则负责沉淀生成结果与检测记录。系统支撑模块贯穿整个流程，承担接口代理、鉴权封装、任务调度、错误处理和结果标准化等基础能力。

在该协同关系中，后端代理层是连接各模块的关键。前端页面只需按照任务类型提交统一请求，后端根据任务配置选择本地模型或外部接口，并将返回结果映射为统一字段。通过这种方式，生成、检测、审核和记录管理能够共享同一套输入输出规范，平台也具备继续扩展新任务的能力。

3.7 本章小结

本章围绕多模态 AIGC 安全分析平台的建设目标，对系统需求和总体设计进行了系统梳理。首先，从课题定位出发，明确了平台需要兼顾研究验证、工程演示和后续扩展三重目标；其次，围绕图像与视频输入、虚假内容检测、不安全内容审核、内容生成与结果管理等环节，对系统功能需求进行了分析；随后，从可扩展性、可维护性、响应性能以及安全性与可部署性等方面，进一步归纳了平台必须满足的非功能需求。

在此基础上，本文提出了由前端展示层、后端代理层和模型推理与外部能力层构成的三层总体架构，并分析了内容检测流程、闭环验证流程和结果追踪流程，完成了平台功能模块与统一输入输出结构的总体设计。通过这一章的分析可以看出，本文系统并非简单堆叠多个模型接口，而是在明确需求约束的前提下，构建了一个具有统一组织逻辑和扩展能力的研究原型平台。

第四章　关键模块与平台实现

第三章从需求和总体架构层面对平台进行了设计，明确了前端展示层、后端代理层、模型推理与外部能力层之间的职责边界。在这一设计基础上，平台实现的关键不只是把各个模型或接口调通，而是要把多源模型能力、外部服务和前端交互组织为稳定的业务流程。为此，系统需要解决异构接口接入、输入输出标准化、任务调度、错误处理、风险展示和部署运行等问题，使图像检测、视频检测、安全审核和内容生成能够在同一平台中协同工作。

4.1　多源检测框架实现

4.1.1　统一能力组织思路

本文平台面临的一个核心问题是，系统所接入的能力来源并不统一。一部分能力来自本地复现模型，例如 UniversalFakeDetect、Stable Diffusion 和 ModelScope Text-to-Video；另一部分能力来自外部平台接口，例如火山引擎视觉智能接口和方舟多模态理解接口。若让前端直接面向这些异构能力，将会面临参数格式不一致、鉴权方式不同、返回结构差异较大和异步机制复杂等问题。因此，系统在实现上首先引入了统一能力组织思路，即由后端代理层将多源能力封装为统一业务接口，再由前端按任务类型进行调用。

这一实现思路对应到代码层面，主要表现为后端服务将所有核心能力组织为检测类接口与生成类接口两大类。其中，检测类接口包括图像 AI 生成检测、视频 AI 生成检测、图像安全审核、视频安全审核以及本地图像伪造检测；生成类接口包括人脸替换、人脸动画、属性编辑、文生图、本地文生图、文生视频、本地文生视频和图生视频等。通过这样的组织方式，前端并不直接感知某个任务究竟来自本地模型还是外部平台，而只需要知道当前调用的是哪一类业务接口。

从系统实现角度看，这种统一封装的意义主要有三点。第一，它降低了前端的复杂度，使页面组件可以围绕“任务逻辑”而不是“能力来源”设计。第二，它为新增模型或更换接口提供了缓冲层，减少改动范围。第三，它使不同能力的结果可以在后端完成标准化处理，为风险展示和实验统计提供统一数据结构。

4.1.2　输入参数与结果结构标准化

多源能力的统一接入不仅体现在接口数量的组织上，更体现在输入参数和输出结果的标准化处理上。对于输入层，平台主要围绕图像与视频两类媒体设计统一请求模式。以图像相关任务为例，后端统一接收 `imageUrl` 或 `imageBase64` 两种形式；视频相关任务则统一接收 `videoUrl` 或 `videoBase64`。这种设计能够同时支持文件输入与链接输入，也便于前端在不同页面之间复用上传、预览与提交逻辑。

在输出层，不同后端能力原生返回的数据结构差异较大。例如，本地检测模型更倾向于返回标签、概率与辅助信息；多模态理解接口则常常返回自然语言或嵌套结构化对象。为避免前端为每种能力单独编写渲染逻辑，系统在后端实现中对这些结果进行了归一化处理。以虚假内容检测为例，平台最终统一关注真假结论、置信度、模型名称、原因说明和辅助展示信息；以不安全内容审核为例，平台统一关注安全与否、建议处置级别、风险标签以及说明性文本。这样一来，前端页面便可以围绕统一字段完成风险标签、进度条、说明卡片和预览区域的展示。

值得注意的是，多模态大模型接口并不总是严格返回纯 JSON 文本，因此系统在实现中还增加了结构提取与容错逻辑。对于图像与视频理解结果，后端会先尝试从模型输出中匹配结构化对象，再执行解析和字段映射。虽然这种方式在工程上增加了一层处理，但它显著提升了结果格式的稳定性，也使大模型接口更适合被纳入一个面向用户的平台中。

多源检测结果的标准化流程如图 4.1 所示。该流程体现了本文平台实现中的一个核心原则：前端只面向统一业务语义，后端负责吸收不同模型和接口之间的格式差异。这样既能降低页面复杂度，也能在后续接入新模型时保持已有交互流程稳定。

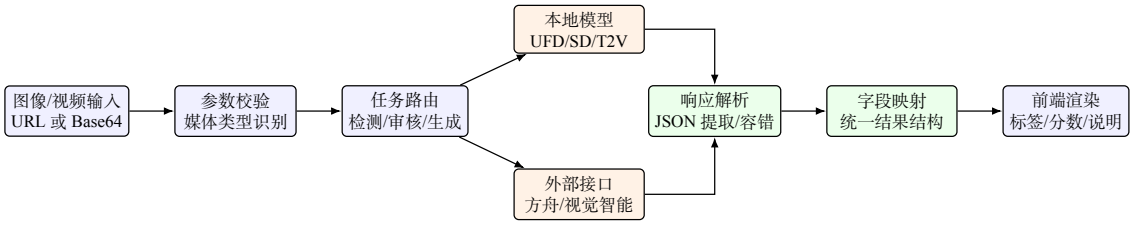

图 4.1: 多源检测结果标准化处理流程

4.2　图像虚假内容检测模块实现

4.2.1　本地检测模型接入实现

图像虚假内容检测模块首先接入了本地部署的 UniversalFakeDetect 模型，用作平台中的自主检测能力和研究基线。该模型服务通过 Python 接口封装后运行在独立端口，对外提供标准 HTTP 接口。为了让前端无需直接访问 Python 服务，Node.js 后端对其进行了再次代理封装：前端只需访问统一的业务接口，后端再根据请求内容将 `imageUrl` 或 `imageBase64` 转换为本地模型所需的字段形式，并转发至本地推理服务。

这种二次代理的实现方式具有明显优势。一方面，它避免了前端同时管理多个服务地址的问题，使前端始终只面向后端代理层。另一方面，后端可以对本地模型返回结果进行错误检查与结构统一。例如，当本地服务不可达、返回非 JSON 结果或状态码异常时，后端可以将错误信息转换为平台层面可理解的提示，从而避免用户面对底层推理服务的原始报错。

从实现效果上看，本地检测模型的接入使平台具备了“可控、可复现、可离线研究”的能力。它并不依赖外部网络环境，也更适合作为论文实验中的基线方法。与此同时，本文并未将其设计为平台唯一的图像检测方案，而是将其与外部多模态检测能力并列放置，从而更符合真实应用中“多源并存”的系统构型。

本地检测链路可进一步拆分为四个步骤。首先，Python 服务启动时读取权重路径、阈值和模型架构配置，并在 `auto` 模式下根据全连接层权重维度推断实际使用的视觉编码器。其次，服务接收 `image_base64` 或 `image_url` 输入，将远程图片下载或 Base64 内容解码为原始图像字节。再次，推理函数完成图像预处理、视觉特征提取和分类头前向计算，得到 0 到 1 之间的伪造分数。最后，服务根据默认阈值 0.5 将分数映射为 `is_ai_generated`，并返回模型架构、阈值、分数和说明文本。Node.js 代理层在收到上述结果后，再将其转化为前端统一的 `isFake`、`confidence`、`model` 和 `details` 字段。

这种实现方式的优点是把“模型推理”和“平台业务”分开处理：Python 服务只关注检测模型能否稳定推理，Node.js 后端只关注请求转发、错误屏蔽和结果结构统一。两者之间通过 HTTP 接口连接，使模型替换与页面迭代互不干扰。

4.2.2　外部图像 AI 鉴别接口接入实现

除本地模型外，平台还接入了基于多模态理解能力的图像 AI 鉴别接口。其核心实现思路是：由后端将输入图像与固定判定提示词组织为统一消息体，提交至支持视觉输入的模型接入点，再从返回结果中抽取真假判断、置信度和原因说明。与传统分类模型不同，这类接口本质上是将图像检测任务转化为“视觉输入 + 自然语言约束 + 结构化输出”的推理过程。

从工程实现角度看，图像 AI 鉴别接口的接入重点不在于算法本身，而在于提示词设计与结果稳定化处理。为此，后端对模型输出格式进行了严格约束，要求其仅返回包含真假字段、置信度字段和原因字段的结构化对象，并将推理温度控制在较低水平，以减少回答波动。对于模型偶尔返回自然语言解释或额外文本的情况，后端再通过正则提取和 JSON 解析实现结果归一化。

该模块与本地模型共同构成了图像虚假检测的双后端方案：前者强调研究可控性和自主部署，后者强调开放场景下的适应性与工程接入效率。前端页面在此基础上提供后端切换选项，使平台不仅能够完成检测任务，也能够为不同方法的实验对比提供直接支撑。

在结果解释方面，外部图像 AI 鉴别接口返回的 `reason` 字段会被前端展示为可

疑痕迹说明；本地 UniversalFakeDetect 返回的模型架构、阈值和判定信息则被组织为辅助说明。二者虽然来源不同，但最终都进入相同的展示区域。这种设计使用户能够在同一页面中比较“本地判别分数”和“多模态解释文本”，也体现了平台对不同检测范式的兼容能力。

4.3　视频虚假内容检测模块实现

4.3.1　视频理解接口接入实现

与图像检测相比，视频真假检测的实现复杂度更高。一方面，视频数据体量更大，上传与传输成本更高；另一方面，当前本地通用视频检测模型的复现与部署成本也明显高于图像场景。基于这一现实条件，平台当前主要采用多模态视频理解接口作为视频 AI 生成检测的主实现方式。具体而言，后端统一接收前端提交的视频 URL 或视频 Base64 内容，将其组织为 `video_url` 类型输入，再与固定的视频真假判定提示词一同发送给多模态理解接口。

这一实现方案的关键不在于简单调用接口，而在于将外部能力转化为平台可用的稳定功能。为此，后端在请求构造时对视频输入格式进行了统一处理，对返回内容执行结构提取和字段映射，并根据置信度范围构造适合前端展示的结论文案。例如，在系统内部，模型原始输出会被进一步整理为是否为伪造、置信度值、模型名称、辅助说明和展示信息等字段，以便前端页面直接渲染。

从系统整体看，这种实现方式反映了本文平台“能力优先、统一封装”的工程策略。虽然当前版本尚未接入本地视频检测模型，但平台架构已经预留了对应位置，使未来若引入训练自由或专用视频检测模型，也可按与图像检测相同的方式纳入统一代理框架。

4.3.2　视频检测结果结构化实现

视频检测结果的结构化处理是该模块实现中的另一个重点。由于视频真假判别往往包含更强的不确定性，平台在结果表达上不能仅停留在简单的真假标签，而应尽量体现模型判断的置信程度和结论层级。基于这一考虑，系统在后端对视频检测输出进一步组织为“真假结论 + 置信度 + 模型名称 + 细节说明”的结构，并在前端以标签、进度条和文本解释等方式进行展示。

这种结构化表达具有两方面作用。首先，它使用户能够直观看到模型对当前视频的判断强弱，而不是被一个绝对化结论所误导。其次，它为不同视频样本之间的对比提供了统一字段基础，使结果统计和人工复核更容易实现。

4.4　不安全内容检测模块实现

4.4.1　图像安全审核模块实现

图像安全审核模块的核心目标是识别图像中是否存在暴力、色情、仇恨、敏感符号或其他违规风险内容，并输出风险标签与处置建议。平台在实现上采用与图像 AI 鉴别相近的技术路径，即通过后端向多模态理解接口发送图像输入和安全审核提示词，再从模型回复中抽取安全结论、建议级别、标签集合和原因说明。

这一模块与虚假内容检测模块的差别主要体现在结果结构上。真假检测关注的是“是否由 AI 生成”，而安全审核关注的是“是否应当通过、复审或阻断”。因此，系统在后端解析结果时，不再将输出映射为真假标签，而是映射为安全状态、风险标签和处置建议，并进一步为前端展示转换为低、中、高不同风险层级。这样的实现方式使平台能够在统一 UI 框架下展示两类不同任务的结果，同时保持业务含义上的清晰区分。

4.4.2　视频安全审核模块实现

视频安全审核模块的实现逻辑与图像审核类似，但在输入组织和结果呈现上更强调视频语义整体性。后端统一接收视频链接或视频 Base64 编码，将其与安全审核提示词一起发送至支持视频理解的模型接口，并在响应后对安全结论、建议级别和标签信息进行标准化处理。前端在展示时则重点突出风险等级和建议说明，以便用户快速判断该视频是否需要人工复核。

在工程实现上，视频安全审核模块还体现了一个重要特点，即其结果不仅服务于页面展示，也为风险分级逻辑提供基础数据。审核模块与全局风险展示模块紧密配合：后端负责产出标准字段，前端负责将这些字段转化为易理解的可视化元素。这种分工方式使系统结构更清晰，也更便于后续统一调整风险分级策略。

为了使图像审核和视频审核结果在页面上保持一致，系统将外部接口中的审核建议字段映射为平台风险等级：`pass` 对应低风险，`review` 对应中风险，`block` 对应高风险；同时将风险标签字段映射为前端标签。表 4.1 给出了当前平台采用的风险映射方式。

表 4.1: 安全审核结果风险映射

接口建议	平台风险等级	页面展示与处理含义
`pass`	低风险	未发现明显违规内容，页面展示为可通过状态，仍保留模型说明用于回溯。
`review`	中风险	存在不确定或边界风险，页面提示建议人工复审，并展示风险标签和原因。
`block`	高风险	存在较明确违规或危险信号，页面展示为高风险并建议阻断或重点核查。

4.5　样本生成与内容管理模块实现

4.5.1　生成模块实现

为了形成“生成—检测—分析”的闭环研究平台，系统实现了两类生成能力：一类是与 Deepfake 相关的人脸替换、人脸动画和属性编辑；另一类是通用场景下的文生图、文生视频和图生视频。前者主要通过火山视觉智能接口和方舟图生视频接口实现，后者则由外部生成接口与本地部署模型共同支持。

在人脸相关生成任务中，系统通过前端表单组织输入内容，并在后端完成图像编码、参数映射和接口调用。人脸替换任务重点处理双图输入与顺序匹配问题；人脸动画任务重点处理首帧图像与文本驱动的联合输入；属性编辑任务则重点支持文本指令与图像内容的组合。通用生成任务中，文生图既支持外部文生图接口，也支持本地 Stable Diffusion 服务；文生视频既支持外部文本到视频接口，也支持本地 ModelScope Text-to-Video 服务；图生视频则通过参考图与文本提示的联合输入实现动态内容生成。

这些生成模块的作用主要体现在两个方面。第一，它们使平台具备了多模态内容生产能力，可为检测模块构造样本。第二，它们验证了平台并不是一个孤立的“内容审查器”，而是一个可用于研究 AIGC 全链路安全问题的原型系统。

图 4.2 展示了平台文生图模块的运行界面。该截图对应“输入提示词—选择生成模型—返回媒体结果”的典型生成流程，能够直观说明系统已经将外部生成能力封装为可交互的前端功能，而不是停留在后端接口调用层面。

4.5.2　数据管理模块现状与实现方式

数据管理模块用于承接生成结果与检测记录的浏览、回看和后续使用。从当前实现情况看，平台已经具备数据管理页面骨架、内容列表展示逻辑和检测记录展示逻辑，但完整的保存、检索和导出功能仍在持续完善中。换言之，该模块在当前版本中更多承担“研究结果组织入口”的角色，而非一个完整的生产级资产管理系统。

当前数据管理模块已经能够作为生成结果和检测记录的统一入口，但尚未扩展为完整的生产级资产管理系统。该设计符合研究原型平台的定位：优先保证生成、检测、审核和结果回看的主流程可运行，同时为后续检索、导出和批量统计功能预留接口。

4.6　风险分级与可视化展示实现

平台在实现上并未将检测结果仅仅停留在接口返回层，而是进一步构建了统一的风险展示方式。对于虚假内容检测，前端主要通过真假标签、置信度进度条、模型名称和原因说明展示分析结果；对于不安全内容审核，则通过风险等级、建议级别、

图 4.2: 文生图生成结果展示界面

风险标签和说明性文本呈现审核判断。通过这种方式，不同任务虽然共享平台框架，但仍能突出各自业务含义。

在可视化实现上，平台前端采用分任务页面组织方式，将生成结果预览、检测结论和辅助说明放在同一页面中展示，以减少用户在不同页面间切换的成本。对于图像任务，页面可直接展示原图与生成图；对于视频任务，页面则以视频播放区域、文字说明和风险标签结合的方式完成展示。此外，前端还通过统一配色、标签体系和响应式布局增强页面一致性，使平台更符合教学展示和系统演示场景。

风险分级与可视化展示模块的实现价值在于，它将底层模型推理结果转化为能够被用户快速理解的信息表达形式。对于毕业论文而言，这也是系统从“模型集合”转变为“平台系统”的关键一步。

4.7　前后端平台开发与部署实现

4.7.1　前端页面与交互实现

前端部分采用 React、TypeScript、Vite 和 Ant Design 构建。根据当前代码结构，系统已经形成首页、Deepfake 生成页、通用生成页、虚假内容检测页、不安全内容检测页和数据管理页六个核心页面。路由层按业务功能进行划分，使不同页面既能独立完成任务，又保持统一导航入口。

在交互层面，前端主要围绕表单输入、文件上传、结果预览和状态提示展开。对

于生成和检测任务，页面通常包含输入区、模型或任务选择区、执行按钮和结果展示区。对于结果较耗时的任务，前端还通过加载状态、提示信息和轮询等待结果等方式改善用户体验。与此同时，前端通过统一的接口访问封装，将所有请求都指向后端代理层，从而避免在页面组件中散落不同服务地址与鉴权逻辑。

平台首页与模块导航界面如图 3.1 所示。首页并不直接承担模型推理任务，而是用于组织生成、检测和内容管理等功能入口，使用户能够从统一入口进入不同安全分析流程。这种页面组织方式能够降低用户理解成本，并保持各功能模块之间的入口一致性。

当前前端页面与核心职责的对应关系如表 4.2 所示。该表反映出本文平台并非单页接口演示，而是围绕生成、检测、审核和结果管理形成了相对完整的功能分区。

表 4.2: 前端页面模块与职责

页面模块	主要输入	核心职责
首页与导航页	无或少量演示入口	展示平台功能分区，引导用户进入生成、检测和数据管理流程。
Deepfake 生成页	源人脸、目标图像、驱动描述或编辑指令	支持人脸替换、人脸动画和属性编辑等典型深度伪造生成任务。
通用生成页	文本提示词、参考图像和生成参数	支持文生图、文生视频、图生视频以及本地生成服务调用。
虚假检测页	图像/视频文件或 URL	提供本地模型与外部接口两类真假检测入口，并展示置信度和原因说明。
不安全检测页	图像/视频文件或 URL	对内容进行安全审核，输出风险等级、风险标签和处置建议。
数据管理页	检测记录和生成结果	组织平台输出结果，支持实验回看和样本管理扩展。

4.7.2　后端代理与任务调度实现

后端服务基于 Node.js 和 Express 实现，是整个平台的能力汇聚中心。它在实现上主要承担四类职责：一是统一接收前端请求并按任务路由至不同能力；二是处理外部接口鉴权，包括 Bearer Token 和 HMAC-SHA256 签名两种主要模式；三是对多模态大模型返回结果进行结构提取与统一封装；四是对异步生成任务执行轮询调度，使前端能够以相对简洁的同步调用方式获得最终结果。

其中，异步任务封装是后端实现中的关键点之一。以视频生成任务为例，外部平台通常采用“提交任务—轮询查询—返回结果”的模式，如果前端直接处理这些步骤，将显著增加页面逻辑复杂度。后端通过统一封装轮询逻辑，将复杂异步流程收敛为单一业务接口，从而大幅简化前端实现，也使任务状态、超时处理和错误提示能够在后端集中管理。

后端代理层对同步检测任务和异步生成任务的处理流程如图 4.3 所示。对于图像检测等同步任务，后端主要完成参数转换、接口调用和结果归一化；对于视频生成等异步任务，后端还需要承担任务创建、轮询查询和超时处理。通过这种封装，前端能够以统一业务接口调用不同能力，系统也因此具备较好的可维护性和扩展性。

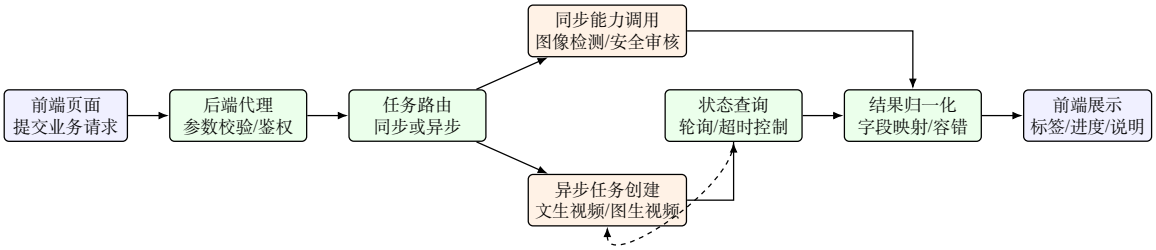

图 4.3: 后端代理层任务调度与结果归一化流程

4.7.3　模型服务部署实现

本地模型服务采用独立进程方式运行，其中图像虚假检测、本地文生图和本地文生视频分别封装为独立服务，并通过不同端口提供推理接口。结合当前项目进展，这些服务与后端代理进程共同部署在实验室服务器中，由前端通过后端统一访问。平台整体采用前后端分离部署方式：前端构建后作为静态页面运行，后端代理与本地模型服务作为独立进程驻留运行。

这种部署方式的优点在于结构清晰、便于调试和扩展。本地模型服务可以按需单独重启和替换，后端代理则负责维持稳定对外接口。由于前端、后端和模型服务之间的边界较为明确，系统运行中出现问题时也更容易定位。尽管当前系统仍然存在视频模型资源开销较大、数据管理能力尚待完善等问题，但从整体上看，该部署方案已经能够支撑平台的核心功能运行。

4.8　本章小结

本章围绕平台关键模块梳理了具体实现方式。首先，围绕多源检测框架，介绍了系统如何通过后端代理实现本地模型与外部接口的统一接入，以及如何完成输入参数和结果结构的标准化处理。随后，分别说明了图像虚假内容检测、视频虚假内容检测、不安全内容审核、样本生成与结果管理等模块的实现逻辑，并分析了风险分级与可视化展示在平台中的作用。

在工程实现层面，本章还总结了前端页面组织、后端代理与任务调度以及本地模型服务部署的主要做法，体现了平台从需求分析到具体落地的完整链路。可以看到，本文系统的特点并不在于某一个单独模型本身，而在于通过统一组织与模块化实现，使多类能力在同一平台中协同工作。

第五章　实验设计与结果分析

实验验证的目标是检验平台能否真实运行、各类能力能否协同工作，以及当前方案的优势与不足。本章根据系统成熟度进行取舍：图像虚假检测以定量验证为主，视频检测与不安全内容审核以链路验证和案例分析为主，系统性能以可用性分析为主。

5.1　实验目标与取舍原则

本章实验主要服务于三个目的：验证图像与视频检测链路能否从输入走到结果展示；分析本地模型与外部接口在不同任务中的适用差异；评估平台在研究验证和演示场景下的可用性。由于当前平台更强调闭环实现与方法接入，本文不做大规模跨数据集排行榜式对比，而优先保留图像检测基线、视频与审核链路验证、同步/异步响应分析三类内容。

5.2　实验环境与评价指标

5.2.1　实验环境

实验在校内实验室服务器环境下完成，平台采用前后端分离与模型服务独立运行的部署方式。前端静态页面提供统一入口，后端代理服务负责请求转发、鉴权和结果归一化，本地模型服务分别承担图像虚假检测、本地文生图和本地文生视频等推理任务。

软件栈方面，前端基于 React、TypeScript、Vite 和 Ant Design，后端基于 Node.js 与 Express，本地推理服务基于 Python、FastAPI 与 PyTorch。外部能力主要来自图像/视频理解接口、生成接口和视觉智能类服务。本文实验不评估硬件极限吞吐，而关注功能链路、结果结构和多源能力适配情况。

5.2.2　评价指标

图像虚假内容检测采用准确率、精确率、召回率和 F1 值作为主要评价指标：

$$Accuracy = \frac{TP + TN}{TP + TN + FP + FN} \tag{5.1}$$

$$Precision = \frac{TP}{TP + FP} \tag{5.2}$$

$$Recall = \frac{TP}{TP + FN} \tag{5.3}$$

$$F1 = \frac{2 \times Precision \times Recall}{Precision + Recall} \tag{5.4}$$

其中，TP、TN、FP、FN 分别表示伪造样本正确识别、真实样本正确识别、真实样本误判为伪造和伪造样本误判为真实的数量。视频检测与安全审核当前以链路完整性、结构化返回和风险展示稳定性为主要评价角度，避免在标注数据不足时给出不可靠数值。

5.3　数据集与测试样本构建

5.3.1　图像真假检测样本

图像真假检测采用两类样本。第一类是仓库中整理完成的 ProGAN 测试样本，包含真实图像 200 张、伪造图像 200 张，标签明确，适合验证本地检测链路。第二类是平台生成与展示样例，包括文生图结果、人脸编辑结果和若干示例图片，用于观察开放场景表现。

实际评测中，本文从 ProGAN 测试集中按真实与伪造各取 100 张，构成平衡的 `progan_mini` 子集，用于验证 UniversalFakeDetect 在当前部署环境中的推理链路。该子集不是覆盖所有生成模型，而是作为快速回归验证集，便于反复确认模型服务、后端代理和前端页面是否正常。

表 5.1: 当前阶段图像真假检测样本构成

样本来源	类别	数量
ProGAN 测试集	真实图像	200
ProGAN 测试集	伪造图像	200
平台样例与生成结果	开放场景补充样本	若干

5.3.2　视频与安全审核样本

视频与安全审核采用“代表性样例 + 功能链路验证”。仓库中的自然场景图像、风险场景图像、短视频样例和生成/伪造素材可覆盖安全图像、风险图像、普通视频和疑似生成视频等输入类型。平台生成结果也可作为补充样本，体现“生成—检测—展示”闭环。

5.3.3 实验样本组织策略

样本组织采用分层策略：有明确标签的图像虚假检测使用结构化样本集；当前难以形成统一标准集的视频检测和安全审核采用代表性案例验证。这样既突出核心成果，也避免用少量样例推导过度结论。

5.4 图像虚假内容检测实验与分析

5.4.1 实验目的与方案

图像虚假检测实验验证两个问题：本地模型能否在结构化样本上稳定判断，外部多模态接口能否补充开放场景解释能力。实验分为本地模型基线验证和开放场景样例分析两部分，前者使用 ProGAN 样本，后者使用平台生成图片和典型示例图片。

5.4.2 阶段性结果分析

本地图像虚假检测模块在 `progan_mini` 子集上的阶段性结果如表 5.2 所示。结果文件由 `results_mini/acc0.txt` 和 `results_mini/ap.txt` 保存，其中 `acc0` 表示以 0.5 为阈值时的真实类准确率、伪造类准确率和总体准确率，AP 表示平均精度。

表 5.2: UniversalFakeDetect 在 ProGAN mini 子集上的阶段性结果

评测集	真实样本	伪造样本	真实类准确率	伪造类准确率	总体准确率	AP
progan_mini	100	100	100.00%	100.00%	100.00%	100.00%

上述结果用于验证本地模型在 ProGAN 分布上的可用性，不能直接代表所有生成模型上的泛化能力。其价值在于证明平台具备可复验的本地检测入口，后续可扩展到扩散模型、压缩扰动和真实业务样本。外部多模态图像 AI 鉴别接口则更适合开放场景分析，可提供自然语言解释，与本地基线形成互补。

图 5.1 展示了平台图像检测结果页面。该案例重点验证“上传输入—调用检测后端—解析返回—可视化展示”的完整链路。

综合来看，图像检测实验说明平台已将可控的本地方法和灵活的外部能力组织到同一页面与同一结果结构中，为后续接入更多模型奠定了基础。

5.5 视频检测与安全审核验证

5.5.1 视频真假检测验证

视频真假检测重点验证视频输入、统一转发、结构化返回和前端展示链路。当前平台主要通过多模态视频理解接口实现，支持视频链接或本地短视频输入，并返回真

图 5.1: 图像虚假内容检测结果展示

假结论、置信度和文本说明。虽然尚未部署完整本地视频伪造检测模型，但平台已具备视频任务基础能力。

5.5.2　不安全内容审核验证

不安全内容审核重点验证链路完整性和结果可解释性。图像审核可返回安全状态、风险标签、建议级别和原因说明；视频审核可生成同类结构，并在前端映射为低、中、高风险等级。样例验证表明，平台已将多模态审核接口转化为可操作功能，而不是停留在单次接口调用。

5.5.3　功能验证结果讨论

视频与安全审核的代表性验证内容如表 5.3 所示。表中未给出大规模准确率，是因为当前样本尚未形成严格标注数据集；本文更关注稳定输入、结构化返回和统一展示能力，并为后续定量实验保留接口基础。

5.6　系统性能与可用性分析

5.6.1　响应特征分析

平台按任务耗时组织响应模式。图像检测和图像审核属于轻量同步任务，适合直接返回；视频生成、图生视频和部分视频理解任务属于长链路任务，需要后端轮询和

表 5.3: 视频检测与安全审核功能验证内容

验证任务	输入形式	返回字段	验证重点
视频 AI 生成检测	视频 URL 或本地短视频 Base64	真假结论、置信度、模型名称、原因说明	验证视频输入能否通过后端统一转发并映射为虚假检测结果。
图像安全审核	图片 URL 或本地图片 Base64	安全状态、风险标签、处置建议、原因说明	验证多模态审核结果能否映射为低/中/高风险等级。
视频安全审核	视频 URL 或本地短视频 Base64	安全状态、风险标签、处置建议、原因说明	验证视频审核链路能否与图像审核共享展示逻辑。
生成结果回检	平台生成图片或视频	真假检测结果或安全审核结果	验证“生成—检测—展示”闭环是否可运行。

状态封装。不同任务的响应方式如表 5.4 所示，这也是后端代理层存在的直接原因之一。

表 5.4: 不同任务的响应组织方式

任务类型	响应模式	后端处理重点	前端展示重点
图像虚假检测	同步返回	Base64 或 URL 转发、分数与字段归一化	显示真假标签、置信度和模型说明。
图像安全审核	同步返回	审核 JSON 提取、标签与建议映射	显示风险等级、风险标签和处理建议。
视频检测与审核	同步或较长请求	视频 URL/Base64 封装、结构化结果解析	显示视频预览、置信度和说明文本。
文生视频/图生视频	异步轮询	任务提交、状态查询、超时控制和结果 URL 提取	显示加载状态、生成结果和失败提示。

5.6.2　平台可用性分析

平台可用性取决于交互链路是否清晰。当前系统已形成内容输入、任务选择、结果展示和样本回流的基本闭环，覆盖首页导航、内容生成、真假检测、安全审核和结果查看等流程。后端代理层屏蔽多源接口差异，并通过错误提示和结构化返回降低理解成本。

5.7　实验结果综合分析

综合实验可知，平台已在图像检测、视频检测和不安全内容审核三个方向形成业务链路。图像任务最成熟，本地模型与外部接口的双后端方案为后续量化对比奠定基

础；视频与安全审核目前偏功能验证，但接入方式稳定，为扩展本地视频模型和大规模审核实验保留了入口。实验不足在于样本规模和视频本地检测能力仍需补强。

5.8　本章小结

本章根据当前项目进展，明确了实验取舍原则，将图像虚假检测作为重点验证方向，将视频检测和安全审核作为功能链路验证方向，并从响应特征和交互流程分析平台可用性。结果表明，平台已完成从内容生成、内容检测到结果展示的基本闭环，但在视频本地检测、样本规模和大规模定量评估方面仍有提升空间。

第六章　总结与展望

6.1　全文工作总结

围绕 AIGC 图像与视频内容的真实性风险和安全风险，本文完成了面向 AIGC 安全的多模态内容检测与分析平台设计与实现。与单一算法复现不同，本文重点在于将图像生成、视频生成、虚假内容检测、不安全内容审核、结果展示与样本管理组织为可运行、可扩展、可验证的整体系统。

在理论与方法层面，本文梳理了 AIGC 图像与视频生成技术、Deepfake 与多模态伪造技术、虚假内容检测方法和不安全内容审核方法，明确平台应同时覆盖“真实性判别”和“安全性审核”两类任务。在系统设计层面，本文设计了前端展示层、后端代理层和模型推理与外部能力层三层架构，完成了功能需求、非功能需求、业务流程、模块划分和统一输入输出设计。

在工程实现层面，本文以前端 React + TypeScript、后端 Node.js + Express、本地模型服务 Python + FastAPI 为基础，接入 UniversalFakeDetect、本地 Stable Diffusion、本地 ModelScope Text-to-Video 以及多类外部图像/视频理解和审核接口，并通过统一代理层实现参数适配、鉴权封装、异步调度和结果归一化。实验验证表明，平台已完成从内容生成到内容检测、再到结果展示的基本闭环，图像任务具备可复验本地基线，视频与审核任务具备稳定功能链路。

综合来看，本文主要完成三项工作：构建了面向 AIGC 安全问题的多模态检测与分析平台；实现了本地模型与外部 API 结合的混合检测思路；围绕当前系统阶段完成了功能验证与可用性分析，为后续扩展更多本地模型和更大规模实验提供了基础。

6.2　存在的不足

当前工作仍存在不足。第一，本地检测能力偏向图像场景，视频检测和安全审核更多依赖外部多模态接口，自主可控性和成本稳定性仍需提升。第二，实验样本规模有限，仍需在类别均衡、生成源多样性、压缩扰动和标注规范方面补强。第三，多源结果融合策略较基础，尚未形成系统的冲突判定、置信度校准和综合风险评分机制。第四，数据管理仍偏原型化，历史记录持久化、批量检索、结果导出和统计分析能力有待完善。

6.3　后续研究展望

后续工作可从四个方向推进。首先，扩展本地检测模型体系，在 UniversalFakeDetect 之外引入 CNNDetection、DRCT 等图像检测方法，并探索轻量级视频检测模型的本地部署。其次，完善数据集与实验体系，将平台生成样本、本地生成模型和公开数据集结合起来，按生成来源、内容场景、后处理方式和风险类别分层组织。再次，推进多模型融合，研究置信度校准、冲突结果仲裁和统一风险评分，使平台从“多能力汇聚”发展为“多模型协同决策”。最后，加强结果管理和可解释性分析，例如图像热力图、视频关键帧、时间轴风险定位和结构化实验报告等能力，以提升平台在真实审查场景中的实用价值。

参考文献

[1] GOODFELLOW I, POUGET-ABADIE J, MIRZA M, et al. Generative adversarial nets[C]//Advances in Neural Information Processing Systems 27. Red Hook, NY: Curran Associates, 2014: 2672-2680.

[2] KARRAS T, AILA T, LAINE S, et al. Progressive growing of GANs for improved quality, stability, and variation[C]//International Conference on Learning Representations. Vancouver: OpenReview.net, 2018.

[3] KARRAS T, LAINE S, AILA T. A style-based generator architecture for generative adversarial networks[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Long Beach: IEEE, 2019: 4401-4410.

[4] HO J, JAIN A N, ABBEEL P. Denoising diffusion probabilistic models[C]//Advances in Neural Information Processing Systems 33. Red Hook, NY: Curran Associates, 2020: 6840-6851.

[5] SONG Y, SOHL-DICKSTEIN J, KINGMA D P, et al. Score-based generative modeling through stochastic differential equations[C]//International Conference on Learning Representations. Virtual: OpenReview.net, 2021.

[6] ROMBACH R, BLATTMANN A, LORENZ D, et al. High-resolution image synthesis with latent diffusion models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. New Orleans: IEEE, 2022: 10684-10695.

[7] SAHARIA C, CHAN W, CHANG H, et al. Photorealistic text-to-image diffusion models with deep language understanding[C]//Advances in Neural Information Processing Systems 35. Red Hook, NY: Curran Associates, 2022: 36479-36494.

[8] RADFORD A, KIM J W, HALLACY C, et al. Learning transferable visual models from natural language supervision[C]//Proceedings of the 38th International Conference on Machine Learning. New York: PMLR, 2021: 8748-8763.

[9] WANG S Y, WANG O, ZHANG R, et al. CNN-generated images are surprisingly easy to spot... for now[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Seattle: IEEE, 2020: 8695-8704.

[10] OJHA U, LI Y, LEE Y J. Towards universal fake image detectors that generalize across generative models[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023: 24480-24489.

[11] TAN C, ZHAO Y, WEI S, et al. Learning on gradients: generalized artifacts representation for GAN-generated images detection[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition. Vancouver: IEEE, 2023: 12105-12114.

[12] CHEN B, ZENG J, YANG J, et al. DRCT: Diffusion reconstruction contrastive training towards universal detection of diffusion generated images[C]//Proceedings of the 41st International Conference on Machine Learning. New York: PMLR, 2024: 7621-7639.

[13] ROSSLER A, COZZOLINO D, VERDOLIVA L, et al. FaceForensics++: Learning to detect manipulated facial images[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Seoul: IEEE, 2019: 1-11.

[14] LI Y, LYU S. Exposing DeepFake videos by detecting face warping artifacts[C]//Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops. Long Beach: IEEE, 2019: 46-52.

[15] CORVI R, COZZOLINO D, ZINGARINI G, et al. On the detection of synthetic images generated by diffusion models[C]//ICASSP 2023 - 2023 IEEE International Conference on Acoustics, Speech and Signal Processing (ICASSP). Rhodes Island: IEEE, 2023: 1-5.

[16] ZHENG C, SUO R, LIN C, et al. D3: Training-free AI-generated video detection using second-order features[C]//Proceedings of the IEEE/CVF International Conference on Computer Vision. Honolulu: IEEE, 2025: 12852-12862.

[17] MIAO Y, ZHU Y, YU L, et al. T2VSafetyBench: Evaluating the safety of text-to-video generative models[C]//Advances in Neural Information Processing Systems 37: Datasets and Benchmarks Track. Red Hook, NY: Curran Associates, 2024.

[18] YEH C, CHANG Y M, CHIU W C, et al. T2Vs meet VLMs: A scalable multimodal dataset for visual harmfulness recognition[C]//Advances in Neural Information Processing Systems 37: Datasets and Benchmarks Track. Red Hook, NY: Curran Associates, 2024.

[19] RUNWAY. Stable Diffusion v1-5 model card[EB/OL]. [2026-04-24]. https://huggingface.co/runwayml/stable-diffusion-v1-5.

[20] ALI-VILAB. Text-to-video-ms-1.7b model card[EB/OL]. [2026-04-24]. https://huggingface.co/ali-vilab/text-to-video-ms-1.7b.

[21] KHAN A A, LAGHARI A A, INAM S A, et al. A survey on multimedia-enabled deepfake detection: state-of-the-art tools and techniques, emerging trends, current challenges & limitations, and future directions[J]. Discover Computing, 2025, 28: 48.

[22] VERDOLIVA L. Media forensics and deepfakes: an overview[J]. IEEE Journal of Selected Topics in Signal Processing, 2020, 14(5): 910-932.

致谢

本论文从选题、系统开发到论文撰写能够顺利推进，离不开许多老师、同学和家人的帮助与支持。在此谨向所有关心和帮助过我的人表示诚挚的感谢。

首先，衷心感谢指导教师在毕业设计全过程中给予的悉心指导。无论是在课题方向的确定、系统方案的设计、研究内容的取舍，还是在论文结构与表达方式的修改上，老师都给予了耐心细致的建议，使我能够逐步从最初的想法整理出较为清晰的研究主线，并在实践过程中不断修正和完善自己的工作。

其次，感谢学院提供的学习环境与实验条件，使本课题能够围绕 AIGC 安全这一具有现实意义的方向持续展开。感谢在项目开发与实验过程中给予帮助的同学和朋友，和大家的交流讨论帮助我在系统实现、模型部署、问题排查和论文写作方面获得了很多启发。

同时，也感谢家人在整个毕业设计期间给予我的理解、支持与鼓励。在课题推进和论文写作压力较大的阶段，家人的陪伴与支持始终是我坚持完成本课题的重要动力。

最后，感谢所有为 AIGC 安全研究、内容治理与相关开源工作做出贡献的研究者和开发者。正是因为这些前人的研究积累与开源成果，本文的系统实现和论文撰写才有了坚实的基础。

谨以此文，向所有帮助、支持和鼓励过我的人致以诚挚谢意。

附录

附录 A 补充代码与接口说明

为便于说明本文系统实现与实验组织的对应关系，现对主要代码模块、功能页面、后端接口及运行端口作补充说明。

1. 前端路由与页面职责。系统前端共包含 6 个核心页面：首页负责平台总览与导航；Deepfake 生成页负责换脸、人脸动画和属性编辑等能力调用；通用生成页负责文生图、文生视频与图生视频任务；虚假内容检测页负责图像与视频真实性检测；不安全内容检测页负责图像与视频审核；数据管理页负责结果浏览与后续扩展的数据管理功能。相关路由集中定义于 `src/routes/index.tsx`。

2. 后端接口组织。后端代理服务集中实现于 `server/index.cjs`，当前已封装的主要接口如表 6.1 所示。

这一组织方式使前端能够通过统一入口调用不同来源的能力，并由后端负责密钥隔离、参数封装和结果归一化。

3. 本地服务运行端口。依据当前系统部署方案，后端代理服务运行在 3001 端口，UniversalFakeDetect 服务运行在 8008 端口，Stable Diffusion 文生图服务运行在 8009 端口，ModelScope 文生视频服务运行在 8011 端口。前端生产环境页面通过静态资源方式部署，实验阶段访问地址可根据服务器配置进行调整。

4. 样本与资源目录。平台实验过程中使用的样本主要来源于三部分：公开数据样本目录 `datasets/`，平台生成和功能验证所需资源目录 `public/mock/`，以及系统实现文档所在的 `docs/` 目录。通过将公开数据样本、平台生成样本和开放场景样本进行组合，本文能够在当前阶段完成针对图像真假检测、视频链路验证和内容安全审核的实验组织。

附录 B 运行与复现实验说明

为保证本课题具备较好的可复现性，本文在系统运行与实验组织方面采用如下约定。

1. 环境配置。前端采用 React、TypeScript 与 Vite 进行构建，后端采用 Node.js 与 Express 实现代理层，本地模型服务采用 Python、FastAPI 与 PyTorch 进行封装。各模

表 6.1: 后端代理服务主要接口

接口类型	接口路径	主要功能
检测类	/api/detect/universal-fake-detect	调用 UniversalFakeDetect 本地模型，对单张图像进行真实/伪造判别。
检测类	/api/detect/volc-image-aigc	调用火山方舟视觉理解能力，对图像是否为 AI 生成内容进行判断。
检测类	/api/detect/volc-video-aigc	调用火山方舟视频理解能力，对视频是否存在 AI 生成或深度伪造风险进行判断。
检测类	/api/detect/volc-ims	调用图像内容安全审核能力，识别暴力、色情、敏感等不安全内容。
检测类	/api/detect/volc-video-ims	调用视频内容安全审核能力，对视频片段进行不安全内容识别。
生成类	/api/generate/faceswap	调用火山视觉智能人像融合接口，实现人脸替换生成。
生成类	/api/generate/seededit	调用 SeedEdit 图像编辑能力，根据文本指令修改输入图像。
生成类	/api/generate/fomm	调用图生视频能力，根据单张人脸图像和动作描述生成人脸动画。
生成类	/api/generate/image	调用火山方舟文生图能力，根据提示词生成图像。
生成类	/api/generate/image-stable-diffusion	转发至自托管 Stable Diffusion 服务，完成本地文生图生成。
生成类	/api/generate/model-scope	转发至自托管 ModelScope 服务，完成本地文生视频生成。
生成类	/api/generate/t2v	调用火山方舟文生视频能力，根据文本描述生成视频。
生成类	/api/generate/i2v	调用火山方舟图生视频能力，根据参考图像和文本描述生成视频。

块通过 HTTP 接口通信，便于本地开发与远程部署切换。

2. 部署方式。项目根目录保留的主要部署脚本和运行方式包括：

- 快速部署.sh：用于前端静态资源构建、上传与快速部署；
- deploy-backend.sh：用于后端代理服务部署、依赖安装与进程启动；
- tmux 会话：用于在实验阶段保持后端代理服务和本地模型服务持续运行；
- 本地开发模式：可通过 npm run dev 同时启动前端页面与本地后端代理，便于接口联调和页面验证。

上述方式分别面向前端页面部署、后端服务部署、长期运行维护和本地联调场景。实验阶段，本地模型服务和后端服务可通过 tmux 会话保持运行，以支持持续调试和结果复核。

3. 实验复现思路。若需复现本文实验，可优先完成后端与本地模型服务的启动，随后从前端页面依次验证图像真假检测、视频真假检测、图像安全审核、视频安全审核以及生成模块。对于图像真实性实验，可直接使用 datasets/test/progan/ 下的样本；对于链路验证任务，可结合 public/mock/ 下的测试媒体进行页面级验证。

4. 说明。由于本文对应系统仍处于毕业设计持续完善阶段，部分模块在后续版本中可能继续调整交互形式、结果展示样式与数据管理能力，但总体架构、接口划分和核心功能链路保持不变。