山东大学本科毕业论文（设计）

面向 AI 生成内容的安全性研究与工具开发

学院：网络空间安全学院

专业：网络空间安全

姓名：麦世徐

学号：202200460157

指导教师：郭山青

2026 年 4 月 22 日

摘　要

随着生成式人工智能技术的快速发展，AI 生成内容在图像生成、视频生成、数字人驱动与智能创作等领域得到广泛应用，但与此同时也带来了虚假合成内容传播、不安全内容扩散、身份伪造和平台审核压力增加等安全问题。围绕 AIGC 内容在真实应用场景中的安全风险，本文以图像与视频两类典型媒体为研究对象，研究虚假内容检测与不安全内容识别方法，并在此基础上设计实现一个多模态内容安全检测与分析平台。

本文首先梳理了 AIGC 相关生成技术、深度伪造技术以及安全检测领域的发展现状，分析现有方法在检测对象、泛化能力、部署成本和工程适配性等方面的特点。随后，围绕图像与视频安全分析任务，构建了由前端展示层、后端代理层和模型推理层组成的系统架构，整合本地部署检测模型与外部多模态审核接口，形成统一的内容输入、检测分析、风险分级与结果可视化流程。系统支持图像与视频文件上传、URL 输入、虚假内容鉴别、不安全内容审核、检测结果展示与内容管理等功能，可为后续实验评估、样本构建和应用验证提供平台支撑。

在论文设计上，本文以当前平台实现为基础，进一步从多模型协同、检测方法比较、风险评分机制和实验评估流程等方面进行扩展设计，以提升论文的系统性和研究深度。本文工作兼顾工程实现与应用价值，可为 AIGC 内容安全治理、网络平台审核以及多模态安全研究提供参考。

关键词： AIGC 安全；多模态检测；虚假内容检测；不安全内容识别；内容安全平台

ABSTRACT

With the rapid development of generative artificial intelligence, AI-generated content has been widely applied to image synthesis, video generation, digital human animation, and intelligent media creation. However, the increasing realism and accessibility of these technologies have also introduced serious security challenges, including forged content dissemination, unsafe media generation, identity misuse, and growing pressure on content moderation. Focusing on the security risks of AI-generated content in practical scenarios, this thesis studies fake content detection and unsafe content recognition for images and videos, and further designs a multimodal content security detection and analysis platform.

This thesis first reviews the development of AIGC generation technologies, deepfake-related manipulation methods, and existing security detection approaches, and analyzes their differences in detection targets, generalization ability, deployment cost, and engineering adaptability. On this basis, a three-layer system architecture is designed, consisting of a front-end presentation layer, a back-end proxy layer, and a model inference layer. By integrating locally deployed detection models with external multimodal review APIs, the platform forms a unified workflow covering content input, security analysis, risk grading, and visualized result presentation. The system supports image and video upload, URL-based input, fake content identification, unsafe content review, result visualization, and output management, which provides an effective foundation for later experiments, sample construction, and application verification.

Beyond the current prototype implementation, this thesis also extends the design from the perspectives of multi-model collaboration, comparative evaluation of detection methods, unified risk scoring, and experimental assessment. Therefore, the work not only reflects the engineering practice of building a deployable tool, but also strengthens the research depth required for an undergraduate thesis in the field of AIGC security.

Key words: AIGC security, multimodal detection, fake content detection, unsafe content recognition, content security platform

目录

第一章　绪论

1.1　研究背景与意义

近年来，生成式人工智能技术快速演进，基于扩散模型、生成对抗网络以及多模态大模型的内容生成方法在图像生成、视频生成、数字人驱动、图像编辑和智能创作等任务中表现出较强能力。AIGC 技术显著提高了数字内容生产效率，降低了内容制作门槛，在媒体传播、广告营销、教育培训、智能交互和数字娱乐等领域展现出广阔应用前景。然而，伴随生成质量不断提升，AI 生成内容与真实内容之间的边界逐渐模糊，其安全风险也日益凸显。

在图像与视频场景中，AIGC 带来的风险主要体现在三个方面。其一，虚假内容风险，即利用文生图、图生视频、换脸、属性编辑等技术生成高度逼真的伪造内容，进而用于误导用户、制造舆论或实施诈骗。其二，不安全内容风险，即借助生成模型输出暴力、色情、仇恨、违法违规等不当信息，对网络空间治理和平台审核造成压力。其三，平台治理风险，即面对海量多模态内容时，单纯依赖人工审核已经难以兼顾效率、准确性与一致性，亟需自动化、可扩展的技术工具辅助安全分析与风险处置。

在这一背景下，围绕 AIGC 内容的真实性与安全性展开研究具有明显的理论意义和应用价值。从理论层面看，系统梳理 AIGC 图像与视频的安全风险类型，比较不同检测方法的适用条件与技术特征，有助于完善多模态内容安全分析的研究框架。从应用层面看，构建面向真实业务场景的安全检测与分析平台，有助于为内容审核、新闻核验、网络治理、品牌保护以及个人权益维护提供技术支撑。因此，开展面向 AIGC 安全的多模态内容检测与分析研究，不仅契合网络空间安全领域的实际需求，也具有较强的工程实践价值。

1.2　国内外研究现状

1.2.1　AIGC 生成技术研究现状

图像生成技术是 AIGC 发展的重要基础。早期研究主要依赖生成对抗网络，通过对抗训练实现图像分布建模，在人脸生成、图像翻译和风格迁移等任务中取得了较好效果。近年来，扩散模型凭借更稳定的训练过程和更优秀的生成质量，逐渐成为主流技术路线。以 Stable Diffusion 为代表的文生图模型在高分辨率图像生成、语义对齐与

细节表达等方面表现突出，并促进了文本到图像、图像编辑和多条件控制等应用的发展。随着相关模型的开源与社区工具链完善，图像生成技术的可获取性显著提高，也使得伪造内容的构造门槛不断降低。

视频生成技术则在时序建模、多帧一致性与跨模态对齐方面持续发展。文本到视频、图像到视频和数字人驱动等技术路线不断成熟，使模型能够根据文本提示或参考图像生成具备连续动作和场景变化的短视频内容。与此同时，Deepfake、人脸替换、人脸动画和属性编辑等深度伪造技术在视觉真实感、动作自然度和局部细节一致性方面持续提升。这些技术一方面为影视制作、虚拟人交互等提供了新工具，另一方面也提升了虚假视频的欺骗性和传播风险，使多模态内容安全问题更加复杂。

1.2.2　AI 生成内容检测研究现状

针对 AI 生成图像与视频的检测问题，国内外研究已形成多条技术路线。较早的方法通常从纹理分布、频域伪影、颜色统计或成像噪声等低层特征出发，利用真实内容与伪造内容之间的分布差异进行判别。这类方法对特定模型或特定数据集往往具有较好效果，但在面对新型生成模型时容易出现泛化不足的问题。

随着深度学习的发展，基于卷积神经网络的伪造检测方法逐渐成为研究重点。这类方法通过监督学习自动提取图像或视频中的判别特征，能够较好地适应复杂视觉模式。但随着生成模型迭代加快，仅依赖某一类训练数据训练得到的检测器在跨模型迁移时仍可能面临性能下降。为提升泛化能力，研究者进一步开始利用大规模预训练视觉模型的通用表征能力，构建跨生成模型的检测方法。此类方法通常以预训练特征为基础，结合轻量分类头或重建对比机制，在未知生成模型场景中表现出更好的鲁棒性。

在视频检测方向，除传统逐帧分类和时序特征建模外，训练自由检测方法、局部与全局联合分析方法以及面向深度伪造特征的专用模型也不断出现。这些方法通常更加关注视频中的时序连续性、嘴型与语音一致性、局部区域不协调等问题。与此同时，多模态大模型逐渐被用于图像和视频的真假判别，能够结合视觉内容与自然语言提示完成结构化分析，在工程上具有较高灵活性。不过，大模型判别仍存在结果稳定性、成本控制和可解释性不足等问题。

1.2.3　不安全内容审核研究现状

相较于真实性检测，不安全内容审核更强调对暴力、色情、仇恨、政治敏感与其他违规信息的识别能力。传统内容审核方法主要建立在图像分类、目标检测与多标签识别模型之上，针对固定类别场景可取得较好性能。随着多模态大模型的发展，安全审核系统开始结合视觉输入与自然语言规则，实现更灵活的内容理解与风险判断，在复杂场景中展现出更强的泛化潜力。

然而，从实际部署角度看，单一方法往往难以同时满足识别范围、推理效率、工程成本与可维护性要求。本地审核模型通常具备自主可控和便于定制的优点，但部署

与更新成本较高；外部审核接口则接入便捷、覆盖面较广，却存在外部依赖和调用成本问题。因此，如何将多源检测能力进行统一组织，并通过平台化方式形成可用的安全分析工具，成为当前研究与工程实践中的关键问题。

1.2.4　现有研究的不足与问题分析

综合现有研究可以发现，AIGC 安全分析仍面临以下几方面问题。首先，图像与视频检测往往分散在不同任务框架中，缺乏能够同时支持多模态输入和多类风险识别的一体化平台。其次，已有方法在实际落地时常常面临“算法效果”与“工程可用性”之间的矛盾，本地模型、云端接口和多模态大模型各有优缺点，但缺少统一的组织与比较机制。再次，检测结果的可解释表达、风险分级展示和应用验证流程仍不够完善，难以直接服务于教学、科研和平台治理场景。基于这些问题，本文拟从系统集成与工程实现的角度出发，构建一个兼顾研究价值与落地可行性的多模态内容安全分析平台。

1.3　研究内容与技术路线

1.3.1　主要研究内容

围绕 AIGC 图像与视频内容的安全风险，本文主要开展以下几个方面的研究。

第一，梳理 AIGC 安全风险及相关技术发展现状。针对图像生成、视频生成和深度伪造技术的发展趋势，分析虚假生成与不安全内容在网络空间中的主要风险形态，为后续检测任务设计提供问题背景。

第二，研究并整合多类检测能力。针对图像虚假检测任务，重点研究具有较好泛化能力的本地检测模型，并结合多模态大模型接口实现图像与视频的真假鉴别；针对不安全内容识别任务，研究图像与视频审核接口的接入方式、结果结构化表示和风险分级策略。

第三，设计并实现一个面向多模态内容的安全检测与分析平台。平台采用前后端分离架构，由前端交互展示层、后端代理调度层和模型推理层构成，实现多类内容输入、统一请求转发、检测结果解析、风险等级展示和历史结果管理等功能。

第四，设计论文层面的扩展方案与实验评估框架。在现有平台原型基础上，进一步考虑多模型协同、检测方法对比、风险评分机制和系统性能测试等内容，使论文不仅停留在功能实现层面，还能够体现方法比较与系统分析的研究深度。

1.3.2　技术路线

本文的技术路线总体上遵循“问题分析、方法整合、平台实现、实验验证”的思路展开。首先，通过调研 AIGC 生成与检测领域的相关技术，明确论文所关注的两类核心任务，即虚假内容检测与不安全内容识别，并梳理图像与视频两类媒体的检测需

求。其次，结合现有开源模型与外部审核接口，构建统一的检测能力接入框架，并通过后端代理实现鉴权封装、接口转发、异步轮询和结果标准化处理。再次，在前端构建面向用户的交互页面，实现内容上传、检测触发、结果展示与数据管理等功能，形成较为完整的分析闭环。最后，围绕检测效果、系统响应性能和平台可用性等方面设计实验与测试方案，为论文结论提供支撑。

1.4　论文特色与创新点

结合当前课题目标与平台建设情况，本文的工作特色与创新点主要体现在以下几个方面。

第一，面向图像与视频场景，构建了兼顾虚假内容检测与不安全内容识别的多模态安全分析框架。与仅关注单一检测任务的系统相比，本文更强调从实际应用场景出发，形成针对多类风险的一体化分析能力。

第二，提出并实现了本地模型与外部接口相结合的混合检测架构。该架构在工程上兼顾自主可控性与快速接入能力，既能够支持本地模型的研究复现，也能够利用外部多模态审核接口提升系统覆盖范围和适用性。

第三，将检测结果可视化、风险分级与平台交互设计纳入整体研究范围，强化了论文在工程实现和应用落地方面的完整性。通过统一的展示与管理流程，平台能够为样本构建、实验比较和系统演示提供较好的支撑。

需要说明的是，本文的创新主要集中在多源检测能力整合、系统设计与工程实现以及实验评估框架设计方面，而不是提出全新的底层检测算法。

1.5　论文结构安排

本文共分为六章，内容安排如下。

第一章为绪论，主要介绍研究背景与意义、国内外研究现状、本文的研究内容与技术路线、特色与创新点以及论文整体结构安排。

第二章为相关技术与理论基础，介绍 AIGC 图像与视频生成技术、深度伪造技术、虚假内容检测方法、不安全内容审核方法以及系统实现所需的关键技术。

第三章为系统需求分析与总体设计，围绕平台目标、功能需求、非功能需求和总体架构展开分析，并给出核心模块划分与业务流程设计。

第四章为关键方法与平台实现，重点介绍多源检测框架设计、图像与视频检测模块实现、不安全内容审核模块实现、风险分级与可视化展示以及前后端平台开发过程。

第五章为实验设计与结果分析，介绍实验环境、数据集与测试样本、评价指标、检测实验、系统性能测试以及实验结果讨论。

第六章为总结与展望，对全文工作进行总结，分析现阶段仍存在的不足，并对后续模型扩展、系统优化和应用落地方向进行展望。

第二章　相关技术与理论基础

第一章已经从研究背景、国内外现状和课题目标的角度说明了 AIGC 安全分析的研究必要性。本章进一步从技术层面对本文涉及的核心问题进行梳理，重点回答三个问题：第一，当前图像与视频生成技术是如何发展的；第二，AIGC 虚假内容与不安全内容的检测方法主要有哪些技术路线；第三，为什么本文需要采用前后端分离、代理调度与模型服务化相结合的工程实现方式。需要说明的是，本章的重点在于建立后文分析与实现所需的理论基础，因此主要介绍代表性方法的基本原理、适用场景与优缺点，而具体的平台模块设计、接口组织方式和实验结果将在后续章节中展开。

2.1　AIGC 图像与视频生成技术基础

2.1.1　图像生成技术演进

图像生成技术的发展大致经历了从生成对抗网络到扩散模型的演进过程。生成对抗网络通过生成器与判别器之间的对抗训练学习数据分布，在人脸生成、图像翻译、风格迁移和属性编辑等任务中取得了较早的突破。该类方法的优点在于生成速度较快，能够在较低推理成本下获得较好的视觉效果，但训练过程往往不够稳定，容易出现模式崩塌，且在复杂场景和高分辨率图像生成方面存在一定局限。

扩散模型的提出改变了图像生成领域的主流技术路线。其基本思想是将真实图像逐步加噪至近似高斯噪声，再训练模型学习逆向去噪过程，从而由噪声逐步恢复出符合文本条件或其他条件约束的图像。以 Latent Diffusion Model 及其工程化代表 Stable Diffusion 为代表的模型，通过在潜空间而非像素空间中进行扩散与去噪，显著降低了计算成本，并在文本对齐、高分辨率细节表达和可控生成能力方面取得了良好效果。与传统 GAN 方法相比，扩散模型在复杂场景生成、语义一致性和编辑灵活性方面更具优势，因此已成为当前文生图、图像编辑和多条件控制任务的主流框架。

从安全分析视角看，图像生成技术的演进意味着伪造内容的来源更加多样。早期针对 GAN 指纹、频域伪影和颜色分布异常的检测思路，在面对扩散模型生成图像时不一定仍然有效。扩散模型生成内容在纹理细节、局部噪声模式和语义一致性上与真实图像更加接近，这直接提高了检测任务的难度，也对检测方法的泛化能力提出了更高要求。

2.1.2　视频生成技术路线

相比图像生成，视频生成不仅需要保证单帧视觉质量，还需要兼顾时间维度上的运动连续性和语义一致性。因此，视频生成模型通常要同时处理空间建模与时序建模两个问题。当前较为常见的路线包括文本到视频、图像到视频以及基于人脸或人体驱动的动画生成三类。

文本到视频模型通常以文本描述作为条件，通过时空联合建模从噪声中逐步生成视频序列。该类模型往往结合文本编码器、时空扩散网络以及视频解码器等多个子模块，以实现从语义描述到动态画面的映射。图像到视频模型则通常在给定首帧图像或参考图像的基础上生成连续帧，更强调主体身份保持、局部结构稳定和动作合理性。与此不同，面向数字人驱动和表情迁移的动画模型通常以关键点、运动场或驱动视频为中间表示，重点解决人物表情、口型、姿态等动态特征的迁移问题。

以本文原型系统中接入的 ModelScope Text-to-Video 类模型为例，其本质上属于基于扩散机制的文本到视频生成模型，通常采用三维卷积或时空注意力结构对视频潜变量进行建模。这类模型能够生成较为自然的短视频片段，但在复杂动作、长时一致性、文字渲染和高保真物理规律表达方面仍存在不足。也正因为如此，视频生成内容中常常会出现局部闪烁、运动不连续、结构漂移和时序逻辑不自然等问题，这些现象为视频安全检测提供了重要线索。

2.1.3　AIGC 生成内容的安全相关特征

从检测角度看，生成模型并非只意味着“更强的内容生产能力”，还意味着“可被识别的技术痕迹”。尽管不同模型产生的伪影形式并不相同，但 AIGC 生成内容通常在以下几个方面呈现可供分析的特征。

第一，低层统计特征差异。生成内容在噪声分布、纹理连续性、频谱结构和压缩残留模式等方面往往与自然采集图像存在差异。第二，局部语义不协调。对于复杂场景、细粒度结构或人脸部位，生成模型可能在局部细节上出现不合理现象，例如边缘结构不稳定、局部区域不连贯等。第三，时序动态异常。视频生成模型虽然能够产生连续帧，但在长时间尺度下仍可能表现出运动规律不自然、物体轨迹不稳定和帧间差异异常等问题。第四，安全对齐不足。生成模型在接收到具有诱导性、规避性或攻击性的提示词后，可能输出具有暴力、色情或其他违规属性的内容，这也是内容安全审查所关注的重要对象。

上述特征决定了本文后续研究需要同时关注两类任务：一类是识别内容是否由 AI 生成或被深度伪造，另一类是识别内容本身是否具有不安全属性。前者更强调真实性与来源分析，后者更强调内容风险等级与平台治理要求。两类任务既有交叉，也有明显差异，因此在技术上通常需要采用不同的检测思路。

2.2　Deepfake 与多模态内容伪造技术

2.2.1　面向人脸的深度伪造技术

Deepfake 是 AIGC 安全研究中最具代表性的风险场景之一。广义上看，深度伪造是指利用深度学习模型对人脸身份、表情、口型、语音或姿态等进行替换、重建和驱动的技术集合。从任务形态上，可以将其大致分为身份替换、表情迁移、口型同步和属性编辑几类。

身份替换任务通常以源人脸和目标场景为输入，将源身份迁移到目标图像或视频中，核心难点在于保持身份特征、光照条件和局部融合自然度的一致。表情迁移任务更关注将驱动视频或驱动关键点中的面部运动映射到静态人物图像上，使目标人物能够完成张嘴、眨眼、点头等动作。口型同步则重点解决语音与嘴部运动的一致性问题，在虚拟人生成和伪造视频制作中均有应用。属性编辑任务则通过文本或标签控制对年龄、发型、妆容、背景和面部局部特征进行修改，虽然未必直接改变人物身份，但同样可能被用于误导性内容生成。

从本文课题角度看，人脸相关生成技术的重要性在于其风险后果更直接。相比一般风景或物体图像，人物图像和人物视频更容易触发身份冒用、名誉损害、舆论误导和诈骗场景，因此相关伪造内容既是虚假检测的重要对象，也是系统功能设计时必须重点覆盖的典型输入类型。

2.2.2　面向通用场景的多模态伪造与编辑技术

除人脸伪造外，当前 AIGC 技术还可用于生成通用场景图像、短视频片段、广告素材、新闻配图乃至高度拟真的事件片段。从安全角度看，这意味着伪造风险已经从“人脸换脸”扩展到“任意内容构造”。在图像层面，文生图模型可以根据自然语言快速构造新闻场景、灾害画面或拟真肖像；在视频层面，文本到视频和图像到视频模型可以进一步生成带有动作和镜头变化的动态内容，使内容看上去更具真实性。

与人脸深度伪造相比，通用场景伪造在检测上更难依赖固定的局部区域规则。人脸伪造任务常可聚焦于面部区域、表情肌理和身份一致性，而通用场景内容则可能涉及物理规律错误、对象关系异常、时序动作不自然以及语义逻辑不一致等更广泛的问题。这也意味着后续检测方法不能仅依赖某一类局部伪影，而需要具有更强的开放域泛化能力。

2.3　虚假内容检测方法

2.3.1　基于低层统计与频域特征的检测方法

较早的伪造检测研究主要依赖图像处理与媒体取证思想，通过分析图像在颜色分布、噪声模式、压缩残留、插值痕迹和频域特征上的异常来识别伪造内容。这类方

法的基本前提是：真实采集图像通常遵循相机成像链路和自然场景统计规律，而经过生成或编辑后的图像在这些规律上会产生偏离。

该路线的优点在于可解释性较强，通常能够指出异常出现的位置或类型，适合与传统数字取证方法结合使用。同时，这类方法在面对某些明显伪造、简单篡改和特定生成模型样本时具有较好效果。然而，其局限也较为明显。一方面，随着生成模型质量提高，很多早期明显的低层伪影已经被削弱；另一方面，这类方法对图像后处理、压缩、裁剪和分辨率变化较为敏感，跨模型和跨场景的泛化能力通常不足。因此，在当前 AIGC 环境下，低层统计方法更多起到辅助分析作用，而较少单独构成完整解决方案。

2.3.2　基于监督分类的检测方法

随着深度学习在视觉任务中的普及，伪造检测逐渐转向监督分类范式。该类方法通常将问题建模为二分类或多分类任务，利用卷积神经网络、Transformer 或其他视觉编码器，从真实样本与伪造样本中学习判别边界。面向人脸伪造的检测任务中，FaceForensics++ 等公开数据集为该类方法提供了较为统一的训练与评估基础，大量研究围绕面部区域裁剪、局部注意力机制、压缩鲁棒性和多任务联合学习展开。

监督分类方法的优势在于能够自动学习复杂伪造特征，并在封闭数据分布内取得较高精度。对于训练集与测试集来源一致、伪造方法相近的场景，此类方法通常具有良好的检测性能。但其关键问题在于对数据分布的依赖较强。当测试样本来自训练阶段未见过的新型生成模型、不同压缩链路或不同模态时，性能往往明显下降。换言之，这类方法较适合作为特定场景下的专用检测器，而不一定天然适用于开放环境中的通用 AIGC 检测。

2.3.3　基于通用视觉表征与重建对比学习的检测方法

为解决监督分类方法在跨模型场景下的泛化不足问题，研究者开始探索基于通用视觉表征的检测路线。此类方法通常利用大规模预训练视觉模型或视觉语言模型提取图像特征，再通过近邻搜索、线性分类头或轻量探测器判断样本的真实性。UniversalFakeDetect 就是这一思路的典型代表。该方法并不依赖从零开始训练复杂的伪造分类器，而是借助大规模预训练特征空间中的判别能力，提高对未知生成模型的适应性。

与之相近的另一类工作是通过重建、对比学习和困难样本构造增强检测器的泛化能力。以 DRCT 为代表的方法强调：如果模型能够区分那些与真实图像高度相似的“困难伪造样本”，则其在面对未知扩散模型时也更有可能保持性能稳定。此类方法通常通过生成高质量重建样本、引入对比约束或改进训练目标，引导模型聚焦更稳定的生成痕迹，而非依赖某个特定模型的表面伪影。

从研究趋势看，基于通用表征和重建对比学习的方法更符合当前 AIGC 检测的发展方向。因为在生成模型快速迭代的现实背景下，检测器不可能针对每个新模型都重

新大规模训练。具有更强跨域泛化能力的方法，更适合支撑本文面向真实场景的通用化安全分析平台。

2.3.4　面向视频的时序检测方法

视频检测相较于图像检测多出一个时间维度，因此检测思路也更强调时序一致性、动作规律和帧间差异分析。传统视频伪造检测方法通常采用逐帧检测后再进行时序聚合，或者直接使用三维卷积网络、循环网络和时空 Transformer 对短视频片段进行建模。这些方法在深度伪造人脸视频场景中取得了一定效果，但对开放域 AIGC 视频的泛化能力仍有限。

近年来，面向通用 AI 生成视频的研究开始重视训练自由或弱训练检测方法。以 D3 为代表的方法从时间差分和二阶动态特征出发，强调真实视频与 AI 生成视频在运动变化规律上的差异，并通过无需大规模训练的方式完成检测。这类方法的启示在于：对于视频内容而言，单帧图像足够逼真并不意味着时间序列也自然合理。生成视频往往在物理连续性、局部运动稳定性和跨帧结构一致性上暴露更多问题，因此时序特征是视频检测中不可忽视的重要维度。

2.3.5　不同检测方法的比较与适用场景

综合来看，不同虚假内容检测方法之间并不存在绝对优劣，而是呈现出明显的适用场景差异。基于低层统计的方法可解释性较强，但对复杂开放场景适应性不足；基于监督分类的方法在特定数据分布内表现优秀，但跨模型泛化较弱；基于通用表征和重建对比的方法更适合开放环境中的图像检测，但往往对预训练特征质量和数据组织方式有较高要求；面向视频的时序检测方法能够利用动态异常提升判别能力，但在计算复杂度和数据处理链路上通常更复杂。

对于本文的研究目标而言，单一方法难以同时满足图像与视频、多源输入、工程可用性和扩展性的需求。因此，从全局设计角度看，采用“本地模型 + 外部多模态接口”的混合思路更加合理：本地模型适合作为可控、可复现的研究基线，外部接口则可弥补多模态和通用场景覆盖能力上的不足。这一判断也将直接影响后续系统架构与功能模块的设计。

2.4　不安全内容检测与安全审查方法

2.4.1　内容安全审查的任务目标

与虚假内容检测不同，内容安全审查关注的不是“内容是否由 AI 生成”，而是“内容本身是否违反平台规则、法律规范或伦理要求”。在 AIGC 场景下，这一任务的重要性体现在两个层面：一方面，生成模型可能被用来主动制造暴力、色情、仇恨、毒品、赌博或其他违规内容；另一方面，即便内容不是明显违规，也可能在边界模糊

场景中造成审核难题，例如擦边内容、暗示性表达、未成年人相关风险和符号化仇恨表达等。

因此，内容安全审查通常需要给出的不仅是一个简单的二分类结果，还包括风险类别、建议处置方式、风险等级以及必要的原因说明。对于本文系统而言，不安全内容检测的目标并不是替代最终人工审核，而是通过自动化分析提供第一道筛查和辅助判定能力。

2.4.2　基于视觉分类的内容审核方法

较为传统的内容审核方法通常建立在图像分类、目标检测与多标签识别模型基础之上。对于暴力、色情、血腥、毒品、武器和符号化风险内容，研究者可以通过构建特定类别的数据集，训练卷积神经网络或视觉 Transformer 完成分类或区域识别。该类方法的优点在于任务定义清晰、推理速度较快、部署链路成熟，适合在已知风险类别较为明确的业务场景下使用。

但其局限也较为明显。首先，不安全内容的边界本身具有较强语境依赖，仅凭视觉局部特征有时难以完成准确判断。其次，面对复合场景、隐喻表达或多模态语义风险时，单纯分类方法的表现会受到限制。再次，图像审核和视频审核虽然在风险类别上具有相似性，但视频任务还需要考虑时间维度上的动作过程和上下文语义，这使得模型设计更加复杂。

2.4.3　基于多模态大模型的安全审查方法

多模态大模型的出现为内容安全审查提供了新的技术路线。这类方法能够同时接收图像、视频与文本提示，并在统一语义空间内对内容进行理解和判断。相较于传统分类器，多模态大模型在开放类别识别、复杂语义推理和结构化结果生成方面具有优势，尤其适合用于需要“判断 + 解释 + 风险建议”一体输出的场景。

在工程实践中，多模态大模型通常可以通过精心设计提示词，将审核任务形式化为结构化输出问题。例如，可以要求模型围绕暴力、色情、仇恨、敏感符号、违法活动等类别给出安全结论、标签集合和处置建议。这种方式的好处在于扩展性强、接入灵活，尤其适合快速构建原型系统和覆盖复杂场景。然而，它也存在结果稳定性受提示词影响、成本较高、推理延迟不可忽视以及内部决策依据不完全透明等问题。因此，在真实系统中，多模态审核通常更适合作为规则系统和传统分类器的补充，而非完全替代。

2.4.4　生成安全评测与防护研究的启示

除了对输出内容进行事后审核，近年来研究者也开始关注生成模型本身的安全评测与前置防护。例如，面向视频生成场景的 T2VSafetyBench 从多类风险维度出发，对文本到视频模型的安全性进行系统评估，说明视频生成不仅需要关注画质与时序

一致性，还应重视内容安全风险。类似地，SafeSora 等工作从人类偏好和有害性约束角度推动视频生成模型的安全对齐，表明生成安全问题正在从“输出检测”逐步扩展到“全流程治理”。

对本文而言，这类研究的主要意义不在于直接照搬其方法，而在于提供两个启示。第一，AIGC 安全分析不应仅局限于真假鉴别，还需要同时考虑内容合规性和风险处置逻辑。第二，安全研究可以分为生成前防护、生成中约束和生成后检测三个阶段，而本文平台主要聚焦于生成后检测与分析，因此需要在结果展示和风险标签设计上兼顾治理视角。

2.5　系统开发关键技术

2.5.1　前端交互与可视化技术

面向 AIGC 安全分析的平台不仅要完成检测任务本身，还需要为用户提供清晰、稳定和可理解的交互界面。因此，前端部分需要承担多模态输入管理、检测流程触发、结果可视化和历史信息展示等职责。React 与 TypeScript 的组合适合构建模块化、组件化的前端系统，其中 React 提供声明式界面开发能力，TypeScript 增强类型约束与可维护性，Vite 则能够提供轻量、快速的开发与构建体验。

从论文整体结构看，前端技术在第二章中只需明确其理论角色：即作为检测平台的人机交互入口，为第三章的需求分析和第四章的具体页面实现提供基础。至于具体页面布局、状态管理方式和交互细节，将在后文系统实现部分展开说明。

2.5.2　后端代理与服务编排技术

由于本文涉及本地模型服务、外部审核接口以及多种输入输出协议，后端层需要承担统一代理与服务编排功能。采用 Node.js 与 Express 构建后端代理具有实现成本低、异步处理能力较强和与前端生态衔接自然等优点。后端代理层的核心作用不只是简单转发请求，更重要的是在系统中承担鉴权封装、参数校验、结果标准化、异步任务轮询和错误处理等职责。

从架构角度看，这一层是实现“多源检测能力统一组织”的关键。若缺少后端代理，前端将不得不直接面向多套接口协议与密钥体系，既不利于安全性，也不利于系统扩展。因此，后端代理技术是将研究原型转化为可部署平台的重要基础。

2.5.3　模型服务化部署技术

本文所涉及的本地检测与生成功能需要以服务化形式接入平台，因此模型服务化部署技术也是系统实现的重要基础。以 FastAPI 为代表的 Python Web 框架能够较方便地将深度学习模型封装为 HTTP 接口，适用于图像检测、视频处理和内容生成等

推理任务。结合 PyTorch 及相关推理框架，可以实现模型加载、输入预处理、结果后处理和状态监测等功能。

模型服务化的价值在于，它将算法模型从单机实验脚本转化为可复用、可调度的系统组件，为后续统一代理和模块化接入创造条件。同时，服务化部署还要求在显存管理、并发控制、容错处理和远程部署方面进行工程优化。虽然这些内容属于后文实现章节的重点，但从理论基础角度出发，本章需要明确：服务化不是附属工作，而是多模型集成平台能够落地的前提条件。

2.6　本章小结

本章围绕本文后续研究所需的核心技术基础，系统梳理了 AIGC 图像与视频生成技术、Deepfake 与多模态内容伪造技术、虚假内容检测方法、不安全内容审核方法以及平台实现所依赖的关键工程技术。综合分析可知，当前 AIGC 安全研究呈现出两个显著特点：一方面，生成模型不断演进，导致伪造内容来源更加多样、逼真程度更高；另一方面，检测与审核方法各有优势和局限，单一技术路线难以同时兼顾泛化能力、工程可用性和多模态覆盖范围。

基于上述认识，本文后续章节将不再重复介绍这些通用技术，而是转入面向课题目标的系统化分析。第三章将在本章理论基础上进一步讨论平台建设需求与总体架构；第四章则结合本文实际原型，说明多源检测框架、关键模块与平台实现方式；第五章将在此基础上给出实验设计与结果分析。

第三章　系统需求分析与总体设计

3.1　系统建设目标

3.2　功能需求分析

3.2.1　图像与视频输入需求

3.2.2　虚假内容检测需求

3.2.3　不安全内容审核需求

3.2.4　结果展示与内容管理需求

3.3　非功能需求分析

3.3.1　可扩展性需求

3.3.2　可维护性需求

3.3.3　响应性能需求

3.3.4　安全性与可部署性需求

3.4　系统总体架构设计

3.5　系统核心业务流程设计

3.6　模块划分与接口关系设计

3.7　本章小结

第四章　关键方法与平台实现

4.1　多源检测框架设计

4.2　图像虚假内容检测模块实现

4.2.1　本地检测模型接入

4.2.2　图像 AI 鉴别接口接入

4.3　视频虚假内容检测模块实现

4.3.1　视频理解接口接入

4.3.2　视频检测结果结构化设计

4.4　不安全内容检测模块实现

4.4.1　图像安全审核模块

4.4.2　视频安全审核模块

4.5　样本生成与内容管理模块实现

4.6　风险分级与可视化展示实现

4.7　前后端平台开发与部署实现

4.7.1　前端页面与交互实现

4.7.2　后端代理与任务调度实现

4.7.3　模型服务部署实现

4.8　本章小结

第五章　实验设计与结果分析

5.1　实验环境与评价指标

5.2　数据集与测试样本构建

5.2.1　公开数据集选取

5.2.2　平台生成样本构建

5.2.3　风险场景样本整理

5.3　图像虚假内容检测实验

5.4　视频内容检测与审核实验

5.5　多方法对比与结果讨论

5.6　系统性能与可用性测试

5.7　实验结果分析

5.8　本章小结

第六章　总结与展望

6.1　全文工作总结

6.2　存在的不足

6.3　后续研究展望

参考文献

致谢

附录

6.4 附录 A 补充代码与接口说明

6.5 附录 B 外文译文

6.6 附录 C 外文原文